

7-5 · Hybrid Search 구현 · 이론 1H

키워드 검색 vs 벡터 검색, Hybrid의 원리

글자가 겹치는가 · 뜻이 통하는가 — 둘을 합친다

수도권ICT 이노베이션스퀘어
데이터 엔지니어링 & RAG 파이프라인 160H · 3기

1시간 뒤에는

- ① BM25 가 무엇을 보고 점수를 매기는지 설명한다
- ② 고유명사·품번은 BM25, 풀어 쓴 질문은 벡터 — 강약을 구분한다
- ③ RRF 가 점수를 버리고 순위만 쓰는 이유를 말한다
- ④ 한국어 공백 토큰화의 한계와 「색인 = 검색 토큰화」원칙을 안다

다음 1H 실습에서 두 검색기를 따로 만들어 같은 질문에 다르게 답하는 것을 봅니다

BM25 — 단어의 빈도와 희소성으로 점수를 매긴다

1 자주 나오면 오른다 — 하지만 포화
「데이터」가 100번 나온다고 10번보다 10배 좋지는 않다

2 흔한 단어는 낮게, 희소한 단어는 높게
「Qdrant」가 들어 있으면 점수가 크게 오른다

3 긴 문서는 불리하게 보정
길면 우연히 단어가 들어 있을 확률이 높기 때문

4 뜻은 전혀 모른다
글자가 겹치지만 본다

한 줄로

글자가
겹치는가

글자를 보는 쪽과 뜻을 보는 쪽

BM25 — 키워드 검색

찾아보기 색인처럼 단어가 그대로 있는가

- 고유명사 · 품번 · 버전 · 오류 코드에 강하다
- 점수는 0~30 같은 값
- 조사가 붙으면 다른 단어가 된다

VS

벡터 검색

단어가 달라도 뜻이 통하는가

- 풀어 쓴 질문 · 다른 표현에 강하다
- 코사인 유사도 0~1
- 숫자·품번 구분이 약하다

2. 각자의 빈틈

질문 다섯 개 — 어느 한쪽이 낫다는 결론이 안 나온다

질문	BM25	벡터
「Airflow 설정 방법」	정확히 찾음	찾음
「일정 관리 도구는?」	놓침 — 단어가 없음	찾음
「v1.2.3 릴리스 노트」	정확히 찾음	약함 — 숫자 구분 못함
「주문번호 A-1002」	정확히 찾음	약함 (7-3 에서 확인)
「배치와 스트리밍 차이」	부분적	찾음

그래서 둘 다 돌리고 결과를 합친다 — 이것이 Hybrid Search

3. RRF — 순위만 가지고 합치기

점수 체계가 달라도 순위만 더한다



점수 = $\sum 1/(k+순위)$ — 그대로 더하면 BM25(0~30)가 코사인(0~1)을 압도하므로 점수를 버린다

양쪽에서 상위였던 B 가 이긴다 · 한쪽에만 있던 C·D 도 살아남는다

3. RRF — 순위만 가지고 합치기

손으로 계산한 RRF — k=60

문서	BM25 항	벡터 항	합계
A	$1/(60+1) = 0.01639$	$1/(60+3) = 0.01587$	0.03226
B	$1/(60+2) = 0.01613$	$1/(60+1) = 0.01639$	0.03252 ← 1등
C	$1/(60+3) = 0.01587$	—	0.01587
D	—	$1/(60+2) = 0.01613$	0.01613

B 는 어느 쪽 1등도 아니었지만 양쪽에서 상위였다 — 1등

3. RRF — 순위만 가지고 합치기

RRF 를 쓰는 이유 네 가지

- 1 정규화가 필요 없다**
점수 체계가 달라도 순위만 쓰기 때문
- 2 어느 쪽 의견도 버리지 않는다**
한쪽에만 있던 문서도 뒤쪽에 남는다
- 3 k 가 상위권의 무게를 정한다**
k 가 작으면 1등과 2등의 차이가 커진다
- 4 구현이 열 줄이면 끝**
그래서 실무에서 널리 쓰인다

대안: 두 점수를 정규화해 가중 합산 — 잘 튜닝하면 낫지만 문서 분포가 바뀌면 가중치를 다시 잡아야 한다 · RRF 는 손덜 것이 k 하나

4. 한국어 토큰화의 한계

「도구는」은 「도구」가 아니다

공백 분리 — .split()

「작업 순서를 관리하는 도구는?」

- ['작업', '순서를', '관리하는', '도구는?']
- 「순서를」≠「순서」·「도구는?」≠「도구」
- 물음표까지 붙는다 — 오늘은 이것으로 원리만

VS

형태소 분석기 — Kiwi

어간을 뽑아 조사를 떼어 낸다

- ['작업', '순서', '를', '관리', '하', '는', '도구', '는']
- 「순서」「도구」가 따로 나온다
- 실무 해법 — 색인·검색 양쪽에 같은 토큰화

이 1시간에서 꼭 가져갈 것

- 1 BM25 는 글자가 겹치는지를, 벡터는 뜻이 통하는지를 본다
- 2 고유명사·품번·버전은 BM25 가, 풀어 쓴 질문은 벡터가 강하다
- 3 RRF 는 점수를 버리고 순위만 써서 두 결과를 합친다
- 4 정규화가 필요 없고 어느 쪽 의견도 버리지 않는다
- 5 한국어 BM25 는 조사 때문에 공백 분리로는 약하다
- 6 색인과 검색의 토큰화는 반드시 같아야 한다 — 다르면 0점만 나온다

7-5 · 이론 1H 마무리

다음은 BM25 · 벡터 검색 구현 실습 (1H)

두 검색기를 따로 만들어 같은 질문에 어떻게 다르게 답하는지 숫자로 봅니다

✓ scroll 로 전량 내려받아 BM25 색인 만들기

✓ 「도구」는 점수, 「도구는」은 0점 — 조사 문제 재현

✓ 질문 유형별 강약 표 만들기

✓ ERR-4021 — 벡터만으로 놓치는 것 확인

준비할 것

Qdrant 컨테이너 · rank_bm25 설치