

7-5 · Hybrid Search 구현 · 실습 1H

BM25 · 벡터 검색 각각 구현 실습

두 검색기를 따로 만들어 같은 질문을 던져 본다

수도권ICT 이노베이션스퀘어
데이터 엔지니어링 & RAG 파이프라인 160H · 3기

1시간 뒤에는

- ① scroll 로 전량 내려받아 BM25 색인을 만든다
- ② get_scores 로 「Airflow」점수를 보고 0.00 과 구분한다
- ③ 「도구」와 「도구는」의 점수 차이로 조사 문제를 재현한다
- ④ 질문 유형별로 BM25 · 벡터의 강약 표를 만든다

여기서 만든 bm25_rank · vector_rank 를 다음 1.5H 에서 RRF 로 그대로 합칩니다

여섯 단계 — ~/data-eng/week7 에서 7-4 환경 그대로

사전 준비: Qdrant 컨테이너 + lecture_kb 컬렉션 + 같은 임베딩 모델(emb) · pip install rank_bm25

1. 내려받기	2. 점수 보기	3. 조사 재현	4. 함수 정리	5.6. 강약·실패
scroll → BM25Okapi	get_scores 「Airflow」	「도구」vs 「도구는」	bm25_rank vector_rank	show() 표 ERR-4021

1단계

핵심 명령 — 내려받아 색인까지 다섯 줄

설치	<code>pip install rank_bm25</code>
내려받기	<code>client.scroll(COLLECTION, limit=1000, with_payload=True)</code>
본문 · id	<code>corpus = [r.payload["text"] ...] · ids = [str(r.id) ...]</code>
색인	<code>bm25 = BM25Okapi([doc.split() for doc in corpus])</code>
확인	<code>print("색인된 문서 수:", len(corpus))</code>

확인 포인트: 색인된 문서 수 = 7-4 에서 적재한 조각 수 · ids 를 str 로 통일해 두는 것이 뒤의 결합에서 중요

점수를 들여다보고, 조사 문제를 재현한다

- 1 get_scores(q.split()) — 「Airflow」**
Airflow 가 든 조각만 점수, 나머지는 0.00 — 무엇을 보는지 숫자로
- 2 「도구」·「도구는」·「도구를 관리」· 긴 질문**
max(s) 를 비교 — 「도구」는 점수가 나오는데 「도구는」은 0점
- 3 왜 0점인가**
조사가 붙으면 다른 단어 — 실무에서 형태소 분석기를 쓰는 이유

찾을 숫자

**0.00 과
최고점**

두 검색기를 같은 모양의 함수로

bm25_rank(query, top_k=5)

get_scores → 정렬 → ids[i] 상위 top_k

- scores = bm25.get_scores(query.split())
- order = sorted(..., reverse=True)
- return [ids[i] for i in order[:top_k]]

VS

vector_rank(query, top_k=5)

query_points 에 emb.embed_query(query)

- hits = client.query_points(...).points
- query=emb.embed_query(query), limit=top_k
- return [str(h.id) for h in hits]

질문 네 개로 강약을 켜다 — show(query)

질문	유형	강한 쪽
「Airflow」	고유명사	BM25
「일정을 정해 두고 도는 작업」	풀어 쓴 질문	벡터
「Kafka 파티션」	고유명사 + 개념	둘 다
「chunk_size 500」	숫자	BM25

show() 가 BM25·벡터 상위 2개를 나란히 찍는다 — 결과를 적어 두세요, 결합이 필요한 이유의 실측 근거

새 문서를 넣고 재색인 없이 검색해 본다

ERR-4021 문장을 upsert 한 뒤, 먼저 재색인 없이 show("ERR-4021") — BM25 는 못 찾는다

넣기	id	재색인 없이	재색인	다시 show()
ERR-4021 문장 upsert	uuid5(manual#ERR-4021)	BM25 가 못 찾는다	scroll 다시 → BM25Okapi 새로	BM25 정확 · 벡터는 엉뚱

왜 안 잡혔나 — BM25 는 메모리 색인

- 1 Qdrant 에 넣어도 자동 갱신되지 않는다**
BM25Okapi 는 만들 때의 corpus 만 안다
- 2 scroll 로 다시 내려받는다**
corpus · ids · text_by_id · bm25 를 새로 만든다
- 3 그다음 show("ERR-4021")**
BM25 는 정확히 찾고, 벡터 검색은 엉뚱한 것을 가져오기 쉽다
- 4 근거**
오류 코드·품번을 다루는 시스템이라면 키워드 검색을 반드시 함께

정리·회고의 「문서를 새로 넣었는데 BM25 에 안 잡힌다」가 바로 이것 — 원인을 겪어 두면 잊지 않는다

이 1시간이 끝날 때 확인할 것

- 1 색인된 문서 수가 7-4 에서 적재한 조각 수와 같다
- 2 「Airflow」검색에서 Airflow 가 든 조각만 점수, 나머지는 0.00
- 3 「도구」는 점수가 나오고 「도구는」은 0점
- 4 bm25_rank · vector_rank 둘 다 str id 를 돌려주고 순위가 다르다
- 5 질문 네 개의 강약 표를 적어 두었다
- 6 ERR-4021 — BM25 는 정확히, 벡터는 엉뚱하게

7-5 · 실습 1H 마무리

다음은 Hybrid 결합과 산출물 완성 (1.5H)

RRF 로 두 순위를 합치고 답변 체인을 붙여 챗봇을 완성한 뒤, 주차 산출물 두 가지를 제출합니다

✓ rrf() 열 줄 — 손 계산 예시로 assert

✓ hybrid_search · 세 방식 비교 · k 실험

✓ prompt | llm | StrOutputParser() 답변 체인

✓ vector-schema.yaml · build_kb.py 제출

가져갈 것

bm25_rank · vector_rank · 강약 표