

7-5 · Hybrid Search 구현 · 정리·회고 0.5H

정리·회고

찾은 근거 안에서만 답하고, 출처를 보여 준다 — 7주차

수도권ICT 이노베이션스퀘어
데이터 엔지니어링 & RAG 파이프라인 160H · 3기

이 시간의 목표

30분 뒤에는

- ① 7-1~7-5 에서 한 일과 남은 결과물을 한 표로 본다
- ② 체크리스트로 오늘 실습을 스스로 점검한다
- ③ 자주 겪는 오류 네 가지의 원인과 해결을 안다
- ④ docker compose version 을 확인해 8주차 Airflow 를 준비한다

7-1 의 「모델이 그럴듯하게 지어낸다」에 대한 답을 오늘 완성했다 — 근거 안에서만, 출처와 함께

이번 주에 만든 것

닷새 — 한 일과 남은 결과물

날	한 일	남은 결과물
7-1	LLM API · 프롬프트 · 멀티턴	챗봇 골격
7-2	문서 로드 · Chunking	조각 기준값
7-3	임베딩 · Qdrant 검색	lecture_notes 컬렉션
7-4	MinIO → Qdrant 파이프라인	lecture_kb 컬렉션
7-5	BM25 + RRF + 답변 생성	RAG 챗봇 · 산출물 2종

7-1 에서 본 문제의 답 — 찾은 근거 안에서만 답하게 하고 출처를 함께 보여 준다

하려는 일 → 코드 한 줄

하려는 일	코드
전량 내려받기	<code>client.scroll(name, limit=, with_payload=True)</code>
BM25 색인	<code>BM25Okapi([doc.split() for doc in corpus])</code>
BM25 점수	<code>bm25.get_scores(query.split())</code>
벡터 순위	<code>client.query_points(...).points → str(h.id)</code>
RRF 결합	$\sum 1/(k + \text{순위}), k=60$
프롬프트 체인	<code>prompt llm StrOutputParser()</code>
컨텍스트 주입	<code>chain.invoke({"context": ..., "question": ...})</code>

여덟 줄로 스스로 확인해 보세요

- 1 BM25 가 무엇을 보고 점수를 매기는지 설명할 수 있다
- 2 질문 유형별로 BM25 와 벡터의 강약이 갈리는 것을 실측했다
- 3 한국어 조사 때문에 BM25 가 0점이 되는 것을 재현했다
- 4 RRF 가 점수 대신 순위를 쓰는 이유를 설명하고 손 계산으로 검증했다
- 5 두 순위의 id 타입을 str 로 통일해야 하는 이유를 안다
- 6 k 값을 바꿔 결합 순위가 달라지는 것을 봤다
- 7 컨텍스트 밖 질문에 「모른다」고 답하고 출처를 붙였다
- 8 산출물 2종을 검증했다 — size 대조 · 두 번 실행 · grep "sk-"

증상으로 찾는 원인과 해결

증상	원인	해결
RRF 결과가 두 배 · 같은 문서가 안 합쳐짐	BM25 는 str, Qdrant 는 int·UUID — 타입 불일치	두 순위 모두 str(id) 로 통일
한국어 질문에 BM25 점수 전부 0	공백 토큰화 — 「도구를」≠「도구」	명사 위주 짧은 질문 · 실무는 Kiwi 로 양쪽 같게
결과 0건 · scroll 문서 수 0	컬렉션 이름 오타 · 다른 모델로 다른 컬렉션	get_collections() 대조 · emb 모델·차원 확인
새 문서가 BM25 에 안 잡힘	BM25 는 메모리 색인 — 자동 갱신 없음	scroll 다시 → BM25Okapi 새로

BM25 가 0점만 내놓으면 가장 먼저 볼 곳 — 색인과 검색의 토큰화가 같은가

자주 나오는 질문 네 가지

1 Qdrant 도 키워드 검색을 지원하지 않나요?

지원한다(sparse vector) — 오늘은 원리를 손으로 만들어 보는 것이 목적

2 검색기를 셋 이상 합칠 수 있나요?

rrf() 에 순위 목록을 하나 더 넣으면 그만 — 그것이 RRF 의 장점

3 답변이 여전히 틀리면?

검색 결과부터 — 근거가 틀렸는지, 근거는 맞는데 모델이 잘못 읽었는지 나눠 본다

4 문서가 수십만 건이면?

메모리 BM25 는 못 올린다 — Elasticsearch·OpenSearch 나 Qdrant 의 sparse vector

Airflow 가 이 모든 것을 자동화한다

1 docker --version · docker compose version
compose version 이 v2 로 나오면 준비된 것

2 docker system df
메모리를 넉넉히 — Docker Desktop → Settings → Resources, 8GB 권장

3 docker stop qdrant minio (선택)
이번 주 컨테이너는 두어도 되고, 자원이 부족하면 멈춰 둔다

8주차 재료

build_kb.py
→ Airflow DAG

다음 회차 예고

8-1 · Airflow 서비스 구축

01

이론 1H

오케스트레이션과
Airflow 개요

02

실습 1.5H

Compose 로
Airflow 기동

03

실습 1H

Airflow 웹 UI ·
CLI 탐색

04

정리 0.5H

구성 요소 복습 ·
환경 상태 점검

준비: Docker Desktop 실행 · 할당 메모리 최소 4GB(권장 8GB) · Spark·Qdrant 등 이전 주차 컨테이너는 꺼 두어도 됨

7-5 · 정리·회고 0.5H 마무리

다음 회차는 8-1 Airflow 서비스 구축

손으로 실행해 온 수집·적재·변환·임베딩을 알아서 돌게 — 지휘자 Airflow 를 직접 띄우고 웹 UI 와 CLI 로 들여다봅니다

✓ cron·수동 실행의 한계와 오케스트레이션

✓ 웹서버 · 스케줄러 · 워커 · 메타데이터 DB

✓ 공식 docker-compose 로 초기화 · 기동

✓ DAG 목록 · Grid 화면 · CLI 기본 명령

준비할 것

Docker 메모리 8GB 권장 · 컨테이너 정리