

8-3 · 수집 → Lake → Spark → VectorDB 흐름 자동화 · 이론 1H

파이프라인 자동화 설계

어디서 자르나, 무엇을 넘기나, 어디서 부르나

수도권ICT 이노베이션스퀘어
데이터 엔지니어링 & RAG 파이프라인 160H · 3기

1시간 뒤에는

- ① 파이프라인 구간을 재시도 가능한 태스크 단위로 자르는 기준을 말할 수 있다
- ② 태스크 사이에 XCom 이 아니라 스토리지 경로를 넘기는 이유를 설명한다
- ③ 같은 compose 의 서비스끼리는 서비스 이름이 주소임을 안다
- ④ SparkSubmitOperator 제출과 파이썬 태스크의 DAG 모양이 같음을 안다

다음 1.5H 실습에서 Qdrant 를 같은 네트워크에 붙이고 앞 세 태스크를 채웁니다

1. 오늘 만들 흐름

7주 동안 손으로 돌리던 다섯 구간을 DAG 하나로



자동화 설계의 핵심은 「어디서 자르느냐」 — 전체를 함수 하나에 넣으면 중간 실패 때 처음부터 다시

어디서 자르나 — 네 가지 기준

- 1 실패·재시도 단위로**
택배의 집하 → 분류 → 배송처럼 단계마다 완료가 기록돼야 문제 지점이 보인다
- 2 비싼 일과 싼 일을 섞지 않는다**
임베딩(비용)과 파일 복사(무료)를 한 태스크에 두면 재시도가 비싸진다
- 3 외부 시스템이 바뀌는 지점에서**
API 호출·스토리지 쓰기·DB 적재는 각각 다른 이유로 실패한다
- 4 너무 잘게 나누지 않는다**
태스크 하나마다 실행 오버헤드가 있고 화면도 복잡해진다

이 파이프라인의 태스크 — 실패 원인과 재시도 비용

태스크	실패 원인	재시도가 싼가
수집(collect)	원천 API 장애·네트워크	싸다 — 재시도 유용
Lake 적재	스토리지 권한·용량	싸다
변환(transform)	데이터 형식 변화·코드 오류	보통
임베딩·적재	API 한도·비용·차원 불일치	비싸다 — 여기가 핵심

임베딩·적재가 핵심 — 여기가 비싸기 때문에 앞 단계와 반드시 떼어 둔다

쪽지에는 「창고 3번 선반」만 — 짐은 창고에

XCom 으로 넘기기

메타데이터 DB 에 저장 — 수 KB 가 한계

- DataFrame 을 넣으면 DB 가 붓는다
- 재시도할 때 앞 태스크도 다시 돌아야
- 적합한 것: 건수·플래그·경로 문자열

VS

스토리지 경로 넘기기

MinIO·파일시스템 — 크기 한계가 사실상 없다

- 실제 데이터는 스토리지에
- 경로만 알면 이어서 재시도
- 넘기는 것은 언제나 「어디에 있는지」

같은 Qdrant 인데 주소가 다르다

- 1 같은 compose 의 서비스끼리는 서비스 이름이 곧 주소**
Airflow 태스크 안에서 → `QdrantClient(host="qdrant", port=6333)`
- 2 호스트 터미널에서는 localhost**
`QdrantClient(host="localhost", port=6333)` — 8-4 Streamlit 도 호스트에서 돈다
- 3 「어디서 실행되는 코드인가」를 먼저 묻는 습관**
컨테이너 안인지 밖인지에 따라 같은 서비스의 주소가 달라진다
- 4 따로 docker run 한 Qdrant 는 다른 네트워크**
이름으로 부르면 「찾을 수 없음」 — 같은 compose 로 옮기거나 docker network connect

주소를 가르는 질문

어디서
실행되나

5. Spark

Spark 는 왜 오늘 안 돌리나

1 실무는 SparkSubmitOperator

대용량 변환은 Spark 클러스터에 제출한다

2 오늘 환경은 단일 노트북

Airflow 여섯 컨테이너에 Spark 까지 올리면 메모리가 부족하다

3 변환은 경량 파이썬 태스크로

Spark 제출은 구조만 확인한다

4 태스크 경계와 의존성 배선은 똑같다

안에서 무엇을 실행하느냐만 다르다

이 1시간에서 꼭 가져갈 것

- 1 실패했을 때 그 단계만 다시 돌리고 싶은 지점이 태스크 경계다
- 2 비싼 일과 싼 일을 한 태스크에 섞지 않는다
- 3 태스크 사이에는 데이터가 아니라 경로를 넘긴다
- 4 같은 `compose` 의 서비스끼리는 서비스 이름이 주소다
- 5 실행 위치(컨테이너 안/밖)에 따라 같은 서비스의 주소가 달라진다
- 6 변환을 파이썬으로 하든 Spark 로 제출하든 DAG 모양은 같다

8-3 · 이론 1H 마무리

다음은 수집 → Lake → 변환 태스크 구현 (1.5H)

Qdrant 를 Airflow 와 같은 compose 에 붙이고, collect·transform·validate 세 태스크를 채워 초록이 되는 것까지 확인합니다

✓ 기존 Qdrant 내리고 compose 에 추가

✓ 컨테이너 안에서 <http://qdrant:6333> 확인

✓ 패키지·OPENAI_API_KEY 전달

✓ 나쁜 문서를 넣어 validate 가 막는지 확인

준비할 것

8-1 Airflow 기동 · OpenAI API 키 · 8-2 분해안