

8-3 · 수집 → Lake → Spark → VectorDB · 정리·회고 0.5H

정리·회고

결과를 점검하고, 8-4 챗봇 화면을 준비

수도권ICT 이노베이션스퀘어
데이터 엔지니어링 & RAG 파이프라인 160H · 3기

이 시간의 목표

30분 뒤에는

- ① 오늘 쓴 방법 여덟 가지를 「하려는 일 ↔ 방법」으로 정리한다
- ② lecture_docs 의 points_count 가 0 보다 큰지 확인해 8-4 를 준비한다
- ③ 체크리스트로 오늘 한 일을 스스로 점검한다
- ④ 자주 겪는 오류 네 가지의 원인과 해결을 안다

비어 있으면 rag_pipeline 을 한 번 더 돌리세요 — 8-4 챗봇은 여기에 든 문서로 답합니다

하려는 일 ↔ 방법 — 여덟 줄

하려는 일	방법
서비스 추가	compose services: 아래에 블록 추가
컨테이너 안에서 부르기	host="qdrant" (서비스 이름)
호스트에서 부르기	host="localhost"
패키지 추가(학습용)	.env 의 _PIP_ADDITIONAL_REQUIREMENTS
환경변수 전달	x-airflow-common environment 에 한 줄
변경 반영	docker compose up -d (restart 는 안 됨)
무거운 import	태스크 함수 안에 둔다
실행 이력	airflow dags list-runs -d <dag>

환경변수·패키지를 바꾼 뒤에는 up -d 로 컨테이너가 재생성되어야 적용된다

다음 차시 준비

8-4 챗봇이 답하려면 Qdrant 에 문서가 있어야

1

points_count 를 센다

`curl -s http://localhost:6333/collections/lecture_docs | grep -o "points_count":[0-9]*'`

2

0 보다 크면 준비 완료

비어 있으면 rag_pipeline 을 한 번 더 트리거

3

챗봇은 호스트에서 돈다

`python -m venv ~/rag-chatbot/.venv — 주소는 localhost:6333`

8-4 에서 부를 주소

localhost

:6333

여덟 개를 스스로 확인해 보세요

- 1 태스크 경계를 정하는 기준과 XCom 에 큰 데이터를 넣지 않는 이유를 안다
- 2 Qdrant 를 Airflow 와 같은 compose 에 추가해 서비스 이름으로 접근했다
- 3 _PIP_ADDITIONAL_REQUIREMENTS 와 OPENAI_API_KEY 를 전달했다
- 4 .env 가 git 에 올라가지 않도록 조치했다
- 5 collect·transform 을 같은 경로에 덮어쓰게 만들고 validate 를 따로 두었다
- 6 나쁜 데이터를 넣어 검증이 실제로 막는 것을 확인했다
- 7 두 번 돌려 points_count 가 늘지 않는 것과 @daily 의 Next Run 을 봤다
- 8 SparkSubmitOperator 제출 방식과 오늘 방식의 공통점을 설명할 수 있다

증상으로 찾는 원인과 해결

증상	원인	해결
qdrant 호스트를 찾을 수 없음 · 연결 거부	별도 docker run 으로 띄워 Airflow 와 네트워크가 다름	compose 에 qdrant 추가 또는 docker network connect
ModuleNotFoundError: qdrant_client	재생성 전이라 반영 안 됨 또는 변수 이름 오타	.env 철자 → up -d → python -c "import ..."
임베딩 호출 인증 오류(API key)	.env 에만 있고 environment: 전달 줄 없음	yaml 한 줄 → up -d → env grep OPENAI
FileNotFoundError	워커마다 다른 컨테이너 로컬 경로에 저장	dags/ 마운트(공유 경로) 실무는 MinIO·S3

컨테이너 이름은 같은 네트워크 안에서만 주소가 된다 · 실습은 dags/ 마운트, 실무는 MinIO·S3

자주 나오는 질문 네 가지

1 실무에서도 dags/ 폴더에 데이터를 두나요?
두지 않는다 — 실습 편의일 뿐, 실무는 MinIO·S3(7-4 에서 만든 방식)

2 태스크가 오래 걸리면 타임아웃이 있나요?
execution_timeout — 없으면 무한정 붙잡아 다른 태스크가 밀린다

3 실패하면 알림을 받으려면?
on_failure_callback 이나 Slack·이메일 프로바이더

4 하루에 여러 번 돌리려면?
schedule 을 "0 */6 * * *" 처럼 크론으로 — 6시간마다

다음 회차 예고

8-4 · Streamlit 기반의 챗봇 인터페이스 개발

01

이론 1H

Streamlit 재실행
원리와 챗 UI

02

실습 1.5H

챗봇 화면 구현
session_state

03

실습 1H

Qdrant 검색·
LLM 연동

04

정리 0.5H

챗봇 구조 요약
최종일 예고

준비: Qdrant 기동 상태 · lecture_docs 에 문서 적재(points_count 확인) · OpenAI API 키

8-3 · 정리·회고 0.5H 마무리

다음 회차는 8-4 Streamlit 챗봇

지금까지는 전부 터미널 안이었습니다 — 질문하면 지식베이스를 뒤져 근거와 함께 답하는 화면을 붙입니다

✓ 상호작용마다 스크립트가 다시 실행되는 원리

✓ `session_state` 로 대화 이력 유지

✓ `st.chat_input` · `st.chat_message`

✓ 질문 임베딩 → Qdrant 검색 → LLM 답변

준비할 것

Qdrant 기동 · 문서 적재 · OpenAI 키