

8-4 · Streamlit 기반의 챗봇 인터페이스 개발 · 실습 1H

Qdrant 검색·LLM 연동

에코 자리에 RAG 3단계를 넣어 실제로 답하게

수도권ICT 이노베이션스퀘어
데이터 엔지니어링 & RAG 파이프라인 160H · 3기

1시간 뒤에는

- ① lecture_docs 의 points_count 를 먼저 확인한다
- ② 화면 없이 search_test.py 로 검색만 따로 시험한다
- ③ app.py 에 임베딩 → 검색 → 답변 생성 3단계를 연결한다
- ④ 근거 개수 조절·약한 근거 경고·오류 화면을 붙인다

화면과 검색을 한꺼번에 만들면 어느 쪽이 틀렸는지 못 찾습니다 — 검색부터

일곱 단계 — 확인 → 검색 → 화면 → 다듬기

8-3 에서 적재한 lecture_docs 가 살아 있어야 시작할 수 있습니다

1. 지식베이스 확인	2. 검색만 시험	3. RAG 챗봇	4·5·6. 다듬기	7. 일부러 실패
curl · points_count	search_test.py	app.py 3단계 연결	개수 슬라이더 · 경고 · 건너뛰기	키 지우고 오류 화면

검색부터 확인 — 화면을 붙이기 전에

1 **curl -s ../collections/lecture_docs**
points_count 가 0 보다 커야 한다 — 0 이면 8-3 rag_pipeline DAG 먼저

2 **search_test.py — 화면 없이 검색만**
OpenAI() · QdrantClient(host="localhost", port=6333)

3 **임베딩 → query_points(limit=3)**
text-embedding-3-small 로 질문을 벡터로, 결과는 .points


4 **python search_test.py**
관련 문서가 점수 순으로 — round(h.score, 3), payload["text"]

확인 안 하면

**「다 모른다고
한다」로 헤멤**

3단계

app.py — 에코 자리에 들어가는 RAG 3단계



`get_clients()` 에 `@st.cache_resource` — 재실행마다 재접속하지 않도록 · `context` 는 검색 결과를 「- 」로 이어 붙인 문자열

system 프롬프트: 「아래 컨텍스트만 근거로 한국어로 답해줘. 컨텍스트에 없는 내용은 모른다고 말해줘」

핵심 줄 — 어디에 무엇을 쓰나

하려는 일	코드
연결 캐시	@st.cache_resource def get_clients():
임베딩	llm.embeddings.create(...).data[0].embedding
검색	qdrant.query_points(..., limit=3).points
컨텍스트	"- " + h.payload["text"] 를 줄바꿈으로 join
답변 생성	llm.chat.completions.create(model="gpt-4o-mini", ...)
근거 표시	with st.expander("검색 근거 보기"):
실행	streamlit run app.py

「Qdrant는 무엇인가요?」에 8-3 문서를 근거로 답하고, 오늘 날씨 같은 질문에 모른다고 하면 프롬프트 제약도 동작

다듬기 세 가지 — 슬라이더 · 경고 · 건너뛰기

1 `limit = st.slider("검색할 근거 개수", 1, 10, 3)`
1 과 10 으로 바꿔 같은 질문 — 적으면 부족, 많으면 흐려진다

2 `THRESHOLD = 0.3` — 우리 데이터로 재 보고 정할 값
`top_score < THRESHOLD` 면 `st.warning(관련 자료가 부족합니다)`

3 근거가 없으면 LLM 을 부르지 않는다
`if not hits or top_score < THRESHOLD: 고정 문구로 답`

7-2 · 7-3

조각 크기 ·
기준값 그대로

API 호출을 건너뛰니 비용이 줄고 응답도 빨라진다 — 「모델에게 물어볼 가치가 있는가」를 먼저 판단하는 실무 패턴

키를 지우고 실행 — 역추적 대신 `st.error`

try/except 없이

파이썬 역추적(traceback)이 그대로 보인다

- OpenAI 인증 오류가 화면에 통째로
- 빨간 역추적 — 사용자에게 보일 것이 아니다
- 기본 예외에 어긋난다

VS

try/except + `st.error`

「답변 생성에 실패했습니다: 오류이름」 한 줄

- `except Exception as e: st.error(...)`
- `st.caption("잠시 후 다시 시도해 주세요.")`
- `answer = None` → 이력에 넣지 않는다

이 1시간이 끝날 때 확인할 것

- 1 curl 결과의 `points_count` 가 0 보다 크다
- 2 `search_test.py` 가 관련 문서를 점수 순으로 출력한다
- 3 「Qdrant는 무엇인가요?」에 근거 있는 답과 `expander` 가 나온다
- 4 무관한 질문에는 모른다고 답하거나 부족 경고가 뜬다
- 5 키를 지우면 역추적 대신 `st.error` 한 줄이 보인다

8-4 · 실습 1H 마무리

다음은 정리·회고 (0.5H)

오늘 만든 챗봇의 구조를 한 표로 정리하고, 자주 겪는 오류와 8-5 최종일 시나리오를 예고합니다

✓ 하려는 일 ↔ 코드 요약표

✓ 오늘의 체크리스트

✓ 자주 겪는 오류 네 가지

✓ 8-5 최종 RAG 챗봇 예고

가져갈 것

돌아가는 app.py · 지우지 말 것