

8-5 · 데이터 파이프라인·최종 RAG 챗봇 · 정리·회고 0.5H

과정 회고·산출물 제출 확인

8주를 돌아보고, 다음에 무엇을 할지 정한다

수도권ICT 이노베이션스퀘어
데이터 엔지니어링 & RAG 파이프라인 160H · 3기

이 시간의 목표

30분 뒤에는

- ① 8주 동안 무엇을 만들었는지 네 가지로 말할 수 있다
- ② 주차별 산출물 여덟 개가 제출 형태로 갖춰졌는지 확인한다
- ③ 자주 겪는 오류 네 가지의 원인과 해결을 안다
- ④ 다음에 공부할 것과 심화 과제를 고른다

이 과정에서 반복된 원칙 — 「고쳤다」는 판정은 되돌려서 확인한다

무엇을 만들었나

8주 동안 만든 것 — 넷

01

데이터 플랫폼

컨테이너 위 한 벌
저장소부터 벡터DB

02

파이프라인

원천에서 답변까지
매일 사람 없이 돈다

03

RAG 챗봇

근거와 출처를
밝히는 답변

04

실패를 고친 경험

일부러 깨뜨리고
되돌려 확인했다

검사기를 만들면 일부러 깨뜨려 보고, 맥등을 주장하면 두 번 돌려 세어 봤다 — 어느 도구를 쓰든 남는 태도

주차별 산출물 여덟 개 — 무엇으로 확인하나

주차	산출물	확인
1주	Docker 실습 환경	컨테이너 기동
2주	ERD·수집 스크립트	테이블 생성·데이터 적재
3주	분석 노트북	집계 결과
4주	Lake 적재 스크립트	Iceberg 테이블
5주	Spark 변환 잡	실행 성공
6주	스트리밍 파이프라인	메시지 소비
7주	벡터 스키마 정의서 · build_kb.py	두 번 돌려 같은 개수
8주	Airflow DAG · RAG 챗봇 앱	엔드투엔드 시나리오

제출 폴더에 .env(실제 키)가 섞이지 않았는지 — grep "sk-" 결과가 비어 있어야 제출 준비 완료

여덟 줄로 줄인 오늘의 체크리스트

- 1 전체 아키텍처를 그림 한 장으로 그리고 구간별 담당 기술을 적었다
- 2 배치와 실시간이 저장소 하나로 만나는 구조를 설명할 수 있다
- 3 최종 DAG 에 @daily·재시도·내용 기반 UUID 를 반영했다
- 4 적재 시각을 챗봇에 표시하고 사이드바에 지식베이스 상태를 띄웠다
- 5 설정을 한곳에 모으고 DAG·챗봇의 컬렉션 이름을 대조했다
- 6 대조군을 먼저 확인한 뒤 새 문서 → DAG → 답변 반영을 성공시켰다
- 7 재실행 시 points_count 가 늘지 않는 것과 재시도 회복을 봤다
- 8 산출물을 제출 형태로 정리하고 키가 섞이지 않았는지 확인했다

전체 열세 항목은 사이트 본문에 — 하나라도 비면 그 단계로 돌아가세요

증상으로 찾는 원인과 해결

증상	원인	해결
DAG 성공인데 챗봇이 모른다	컬렉션 이름 불일치 또는 이전 DAG 트리거	세 곳 이름 대조 · collect 로그 건수 확인
재실행마다 points_count 증가	포인트 id 가 순번(enumerate)	내용 기반 uuid5 로 upsert 한 건 유지
수동은 되는데 자동 실행 안 됨	paused 상태 또는 첫 @daily 시각 전	unpause 확인 · 다음 실행 예정 시각 읽기
지운 문서를 계속 답한다	incoming 삭제해도 Qdrant 포인트는 남음	컬렉션 비우고 재적재 또는 삭제 태스크 추가

수업 시연은 수동 트리거로 진행해도 된다 · 삭제는 이번 파이프라인이 다루지 않는 구멍(7-4 와 같다)

자주 나오는 질문 네 가지

1 이걸 실무에 그대로 쓸 수 있나요?

구조는 그대로 — 저장소를 S3 로, 실행을 Kubernetes 로, 비밀값을 Secret 관리로 바꾼다

2 다음에 무엇을 공부하면 좋을까요?

데이터 품질(Great Expectations) · 데이터 계보(lineage) · dbt · 클라우드 관리형 서비스

3 배운 것을 잊지 않으려면?

작은 개인 파이프라인을 하나 만들어 매일 돌려 보세요 — 관심 있는 데이터면 무엇이든

4 이 사이트의 자료를 나중에도 볼 수 있나요?

과정 종료 후에도 열려 있다 — 실습 환경만 각자 다시 세우면 된다

과정이 끝난 뒤 이어 갈 다섯 가지

- 1 처리한 incoming 파일을 날짜 폴더로 옮기는 archive 태스크를 DAG 끝에
- 2 `st.write_stream` 으로 답변을 스트리밍해 체감 응답 속도 개선
- 3 7-5 의 하이브리드 검색(BM25 + RRF)을 챗봇에 옮겨 붙이기
- 4 incoming 에 없는 문서를 Qdrant 에서 지우는 삭제 태스크 설계
- 5 S3 + 관리형 Airflow 로 옮기면 무엇이 달라지는지 정리

참고: [Airflow best-practices](#) · [Streamlit](#) · [Qdrant 공식 문서](#) — 링크는 사이트 본문에

과정 마무리

8주 과정을 마칩니다

원천에서 답변까지 사람이 손대지 않아도 매일 도는 시스템을 만들었습니다 — 어느 도구를 쓰든 남는 태도와 함께

✓ 주차별 산출물 여덟 개 제출 확인

✓ 제출 폴더에 실제 키가 있는지 마지막 grep

✓ 작은 개인 파이프라인 하나를 매일 돌려 보기

✓ 사이트는 과정 종료 후에도 열려 있습니다

남기는 한 문장

「고쳤다」는 되돌려서 확인한다