프로젝트 M1 · 기초 미니 · 코랩 · 3~4시간

서울 따릉이 대여 패턴

42만 건으로 「언제, 어디서」 답하기

수도권ICT 이노베이션스퀘어
데이터 엔지니어링 & RAG 파이프라인 160H · 3기

이 프로젝트의 목표

다 끝내면 말할 수 있는 것

① 가장 붐비는 시간대와 평일 · 휴일의 차이

② 가장 많이 빌려 간 대여소 10곳

③ 「빌렸다가 바로 반납한」 기록을 빼야 하는 이유

1~3주차에 배운 pandas 와 DuckDB 만으로 한 바퀴를 돕니다

데이터

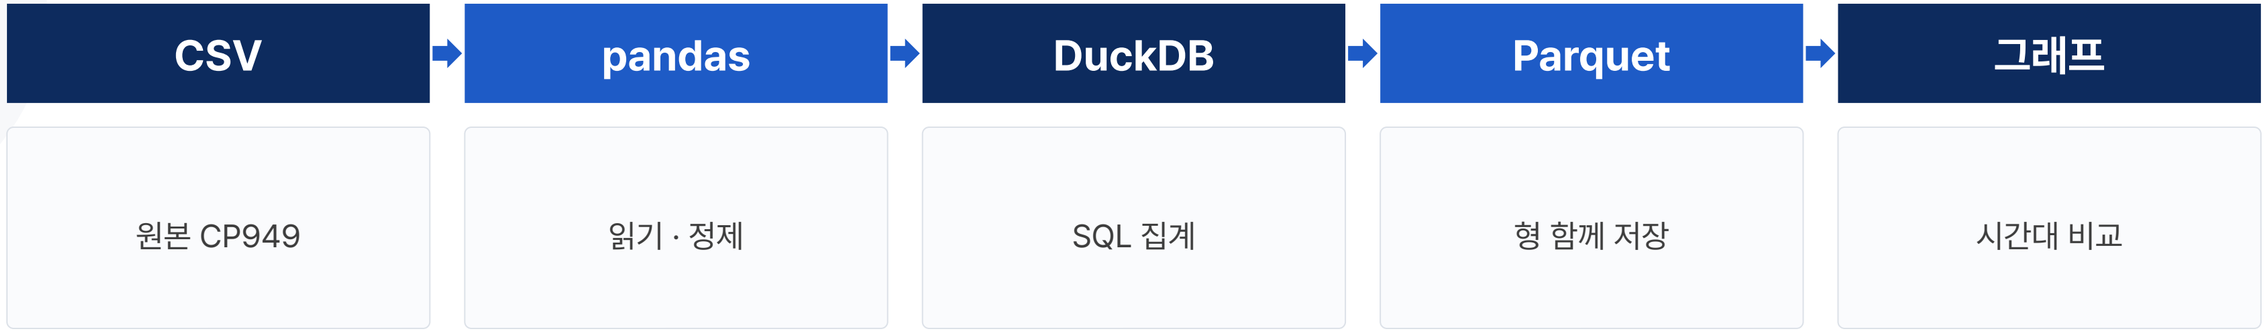
서울시가 공개한 실제 대여 기록

항목	내용
출처	서울 열린데이터광장 OA-15182
기간	2026-06-05(금) ~ 06-07(일)
규모	427,258행 · 16개 열
형식	CSV · CP949 인코딩
이용허락	공공누리 1유형(출처표시)

원본은 한 달 418만 건(약 730MB) — 실습용으로 사흘치만 잘랐다

흐름

CSV 한 장에서 그래프까지



적재 없이 DuckDB 가 pandas 표를 그대로 SQL 로 읽는다

단계

7단계로 따라 합니다

1. **1~2. 준비 · 읽기**
   데이터 받기, 인코딩을 일부러 틀려 실패한 뒤 CP949 로 읽기

2. **3. 정제**
   열 이름 · 형 바꾸기, 1분 안에 같은 곳 반납한 13,046건 빼기

3. **4~5. 집계**
   시간대 · 날짜별 정점(윈도 함수), 대여소 10곳

4. **6~7. 저장 · 더 해 보기**
   Parquet 저장 · 그래프, 오간 구간 10개

일부러 실패해 보기

그냥 읽으면 깨진다 — 인코딩

기본(UTF-8)으로 읽기

UnicodeDecodeError 로 멈춘다

- 공공기관 CSV 는 아직 CP949 가 많다
- pandas 기본값은 UTF-8

VS

encoding="cp949"

dtype=str 까지 주면 대여소 번호 앞 0 도 산다

- 00502 가 502 로 바뀌지 않는다
- 숫자 · 날짜는 열마다 골라 바꾼다

확인 포인트

이 숫자가 같게 나오면 맞습니다

정제 후	414,212건(바로 반납 13,046건 제외)
최고 시간	18시 35,888건 — 17시 · 19시가 뒤를 잇는다
날짜별 정점	금 18시 16,833 · 토 18시 10,117 · 일 17시 9,337
대여소 1위	한강버스 망원 선착장 2,235건

프로젝트 M1 · 기초 미니 마무리

M1 마무리

정제 하나가 순위를 바꾼다는 것을 직접 확인했습니다

- ✓ 반납 대여소까지 써서 오간 구간 10개 뽑기
- ✓ 240분 넘는 기록, 뺄지 남길지 정하기
- ✓ 한 달치로 늘리면 P2(날씨 × 따릉이)로

다음 프로젝트

P2 날씨 × 따릉이 수요