프로젝트 M2 · 기초 미니 · 코랩 · 3~4시간

우리 동네 대기질 리포트

우리 구는 1년에 며칠이나 나빴나

수도권ICT 이노베이션스퀘어
데이터 엔지니어링 & RAG 파이프라인 160H · 3기

이 프로젝트의 목표

다 끝내면 말할 수 있는 것

① 7일 이동평균으로 본, 오래 나빴던 때

② 초미세먼지 「나쁨」 날이 가장 많은 구와 적은 구

③ 순위를 매길 때 rank() 와 row_number() 의 차이

④ 기본 키가 같은 자료를 두 번 넣는 실수를 막는 방법

2주차 SQL(윈도 함수 · CTE)을 DuckDB 파일 DB 에서 그대로 씁니다

데이터

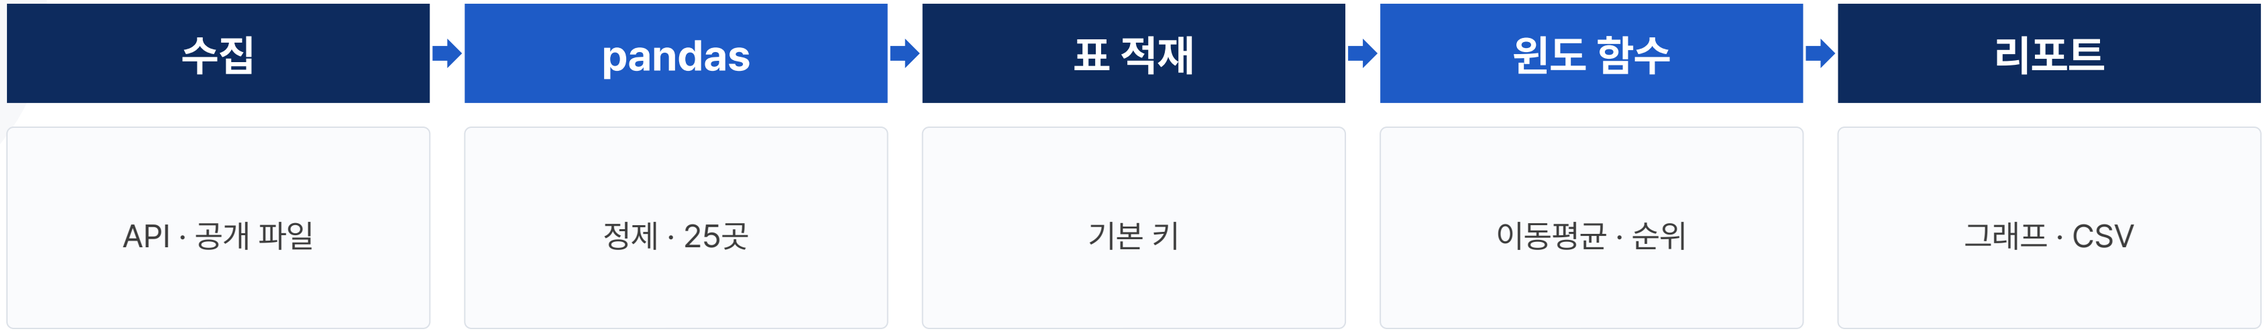
서울시가 확정해 공개한 일평균 농도

항목	내용
출처	서울 열린데이터광장 OA-2218
기간	2025-01-01 ~ 12-31
규모	측정소 50곳 × 365일 = 18,250행
형식	CSV · CP949(gz 압축)
이용허락	공공누리 1유형(출처표시)
직접 수집	에어코리아 대기오염통계 API

에어코리아 API 는 최근 3~6개월 실시간 자료라 키가 있을 때만 직접 받는다

흐름

공개 파일에서 자치구 리포트까지



Colab 에는 MySQL 이 없어 같은 SQL 이 도는 DuckDB 파일 DB(air.duckdb)에 적재한다

단계

8단계로 따라 합니다

1

1~2. 준비 · 수집

인증키는 보안 비밀에, 날짜 열은 글자로 읽은 뒤 형식을 주어 바꾸기

2

3~4. 정제 · 적재

「구」로 끝나는 측정소 25곳, 기본 키 (날짜, 측정소) 표에 넣기

3

5~6. 윈도 함수

7일 이동평균, 「나쁨」 일수와 rank · dense_rank 순위

4

7~8. 저장 · 더 해 보기

강동구 그래프, 리포트 CSV(utf-8-sig), PM10 · 연속 나쁨

일부러 실패해 보기

네 번 막혀 보고 고칩니다

실패	원인	고친 법
날짜가 1970년이 된다	20250101 을 정수로 읽음	글자로 읽고 format 지정
두 번째 INSERT	같은 날 · 측정소 중복	기본 키가 막아 준다
WHERE 에 이동평균	윈도는 WHERE 뒤에 계산	CTE 로 감싸 바깥에서
빈칸 많은 창이 1위	값 한두 개로 평균	n7 >= 5 인 창만

확인 포인트

이 숫자가 같게 나오면 맞습니다

자치구 표	9,125행(25곳 × 365일), pm25 빈칸 53개
이동평균 1위	강동구 2025-01-23, 7일 평균 61.7μg/m³
「나쁨」 일수	강동구 · 구로구 54일 공동 1위, 서초구 rank 3 · dense_rank 2
달별	3월 286(구 · 일)이 가장 많고 10월은 0

프로젝트 M2 · 기초 미니 마무리

M2 마무리

윈도 함수는 창 안의 개수와 동점까지 함께 봐야 합니다

- ✓ 미세먼지(PM10)로 다시 세어 순위 비교하기
- ✓ 「나쁨」이 연속으로 며칠 이어졌나 구하기
- ✓ API 로 최근 한 달을 받아 이어 붙이기

다음 프로젝트

M3 지하철 혼잡 시간표