프로젝트 M3 · 기초 미니 · 코랩 · 3~4시간

지하철 혼잡 시간표

오전 8시, 어디서 타고 어디서 내리나

수도권ICT 이노베이션스퀘어
데이터 엔지니어링 & RAG 파이프라인 160H · 3기

이 프로젝트의 목표

다 끝내면 말할 수 있는 것

① 같은 자료가 두 번 들어간 달을 찾고 지운 방법

② 열 48개짜리 넓은 표를 긴 표로 바꾸는 이유

③ 오전 8시 타는 역 1위와 내리는 역 1위

④ MinIO 에 올린 파일을 SQL 엔진이 바로 읽는 방법

4주차 레이크하우스의 축소판 — Trino 자리는 DuckDB httpfs 가 맡습니다

데이터

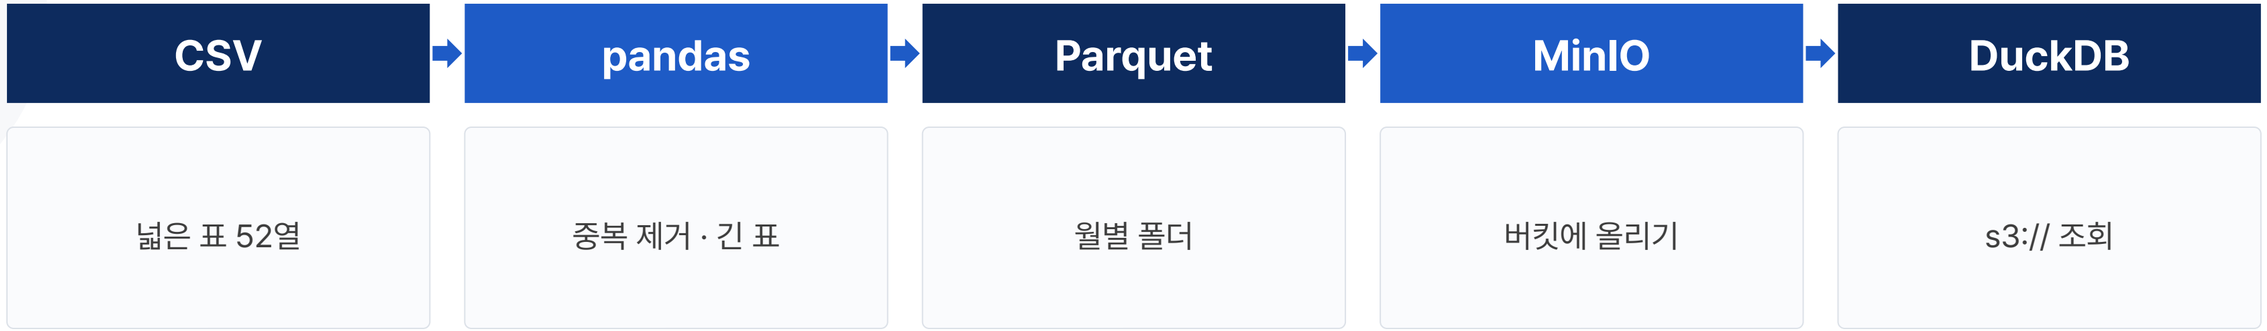
역별 · 시간대별 승하차 인원

항목	내용
출처	서울 열린데이터광장 OA-12252
기간	2026년 1~9월(월별)
규모	6,830행 · 52개 열
형식	CSV · CP949(gz 압축)
이용허락	공공누리 1유형(출처표시)

전체(2015년부터, 8만 5천여 행)에서 2026년 1~9월만 원본 그대로 잘랐다

흐름

넓은 CSV 에서 s3:// 조회까지



Colab 에는 Docker 가 없어 MinIO 실행 파일을 받아 백그라운드로 띄운다

단계

8단계로 따라 합니다

1. **1~3. 준비 · 읽기 · 긴 표**
   기본 키 검사로 겹친 행 찾기, melt 와 정규식으로 시각 · 승하차 꺼내기

2. **4. Parquet 저장**
   ym 으로 폴더를 나누는 Hive 파티션, 다시 돌려도 같은 파일 이름

3. **5~6. MinIO · 조회**
   체크섬 확인 후 띄우기, SECRET 등록, 시간대마다 rank()

4. **7~8. 그래프 · 더 해 보기**
   시간대별 승하차 막대, 8시 하차 1~3위 역의 하루 모양

일부러 실패해 보기

다섯 번 막혀 보고 고칩니다

실패	원인	고친 법
기본 키가 겹친다	3월 · 7월이 두 번 실림	모든 열 같으면 drop_duplicates
글자를 숫자로	'04시-05' 는 숫자 아님	정규식 extract
ym 열이 없다	값이 폴더 이름에만 있음	hive_partitioning=true
버킷 없이 올리기	버킷을 먼저 만들지 않음	make_bucket 뒤 올리기
HTTP 403	비밀번호가 틀림	바른 값으로 다시 등록

확인 포인트

이 숫자가 같게 나오면 맞습니다

중복 제거	겹친 1,241행 삭제 → 5,589행
긴 표	268,272행(5,589 × 48), Parquet 파일 9개
8시 1위	타는 역 2호선 신림 · 내리는 역 7호선 가산디지털단지
18시	하루 중 가장 붐비는 시간, 타는 역 1위는 2호선 강남

프로젝트 M3 · 기초 미니 마무리

M3 마무리

겹친 두 달을 지우지 않으면 승객이 두 배로 잡힙니다

- ✓ 승차 + 하차로 역 전체 혼잡 순위 다시 매기기
- ✓ 달마다 8시 하차 1위가 같은지 확인하기
- ✓ 2019년과 2026년의 8시 승하차 비교하기

다음 프로젝트

M4 보도자료 모으기