프로젝트 M4 · 기초 미니 · 코랩 · 3~4시간

보도자료 모으기(비정형 입문)

최근 7일, 정부가 가장 많이 말한 낱말

수도권ICT 이노베이션스퀘어
데이터 엔지니어링 & RAG 파이프라인 160H · 3기

이 프로젝트의 목표

다 끝내면 말할 수 있는 것

① 부처마다 다른 날짜 형식을 하나로 맞추는 방법

② 라이브러리가 오류 없이 조용히 틀리는 경우

③ MongoDB 에 같은 글이 두 번 들어가지 않게 막는 방법

④ RSS 로 한 주를 빠짐없이 담으려면 필요한 것

2주차 MongoDB · 수집 기초로 모양이 제각각인 글 묶음을 다룹니다

데이터

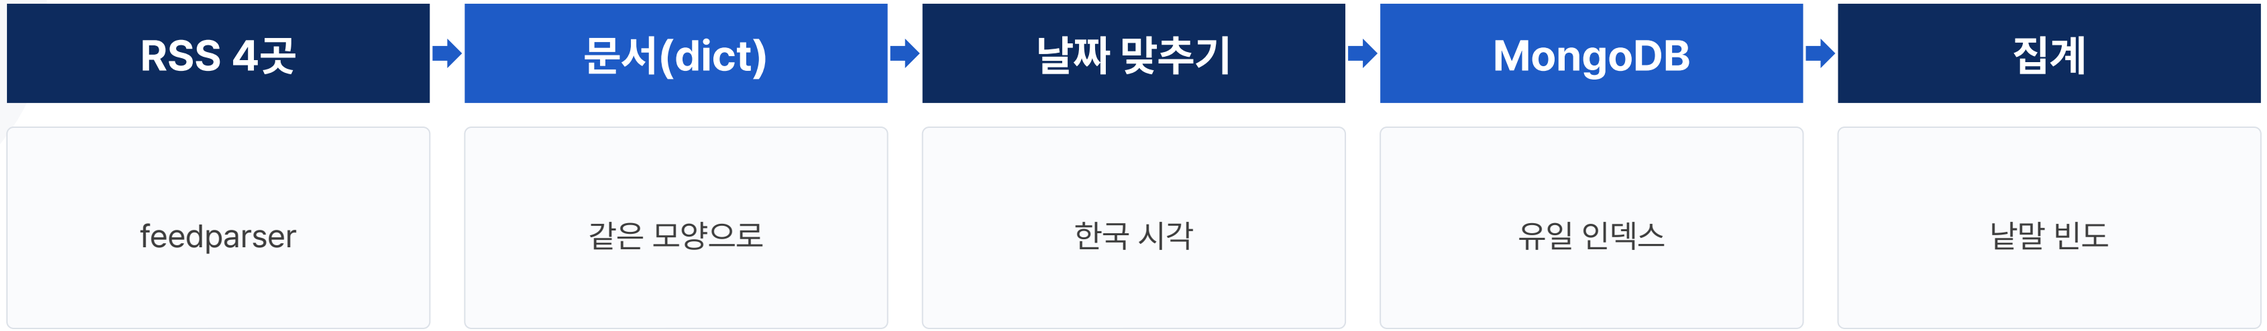
부처 네 곳의 보도자료 RSS

항목	내용
출처	과기정통부 · 복지부 · 행안부 · 농식품부
수집 시각	2026-10-28 22시 스냅샷
규모	155건(50 · 30 · 25 · 50)
형식	RSS(XML) → JSONL
이용허락	공공누리 제1유형(출처표시)

RSS 는 날마다 바뀌어 같은 코드로 받아 둔 스냅샷을 함께 쓴다 — 확인 숫자는 스냅샷 기준

흐름

RSS 네 곳에서 낱말 빈도까지



Colab 에는 MongoDB 서버가 없어 같은 명령을 흉내 내는 mongomock 을 쓴다

단계

9단계로 따라 합니다

1. **1~3. 준비 · RSS 모으기**
   robots.txt 확인, User-Agent 를 붙여 네 부처를 1초씩 쉬며 받기

2. **4~5. 날짜 · 적재**
   네 가지 날짜 형식을 KST 로, 링크에 유일 인덱스를 건 컬렉션

3. **6~7. 범위 · 낱말**
   부처별로 담긴 기간 확인, 조사 떼기 · 불용어로 $unwind 집계

4. **8~9. 저장 · 더 해 보기**
   JSONL · CSV 저장, 날짜별 그래프, 매일 모아 빈틈 메우기

일부러 실패해 보기

멈추는 오류보다 조용한 오답이 위험하다

실패	원인	고친 법
korea.kr RSS 404	2026-07-01 서비스 종료	부처 RSS 에서 직접
to_datetime 멈춤	부처마다 날짜 형식이 다름	형식별 정규식 함수
10-28 이 10-01 로	feedparser 가 조용히 틀림	parse_date 직접 작성
같은 글 다시 넣기	어제 글이 또 온다	link 유일 인덱스

확인 포인트

이 숫자가 같게 나오면 맞습니다

적재	155건, 요약 있는 글 90건 · 없는 글 65건
수집 범위	행안부는 10/22 12:00 부터라 빼고 세 부처만
최근 7일	세 부처 57건, 날짜별 [12, 8, 0, 0, 17, 8, 12]
낱말 1위	AI 11번(인공지능 6 + AI 5), 2위 미래 7번

프로젝트 M4 · 기초 미니 마무리

M4 마무리

모양이 제각각인 문서를 한 컬렉션에 담고 셀 수 있게 됐습니다

- ✓ live 를 ordered=False 로 이어 넣어 빈틈 메우기
- ✓ 제목 대신 요약으로 낱말 세어 비교하기
- ✓ 부처마다 1위 낱말 뽑기

다음 프로젝트

P5 보도자료 요약 · 검색기