프로젝트 M6 · 기초 미니 · 코랩 · 3~4시간

법령 조문 찾기

LIKE 와 BM25, 한국어에서 어디서 틀리나

수도권ICT 이노베이션스퀘어
데이터 엔지니어링 & RAG 파이프라인 160H · 3기

이 프로젝트의 목표

다 끝내면 말할 수 있는 것

① LIKE 와 BM25 가 각각 잘하는 것과 못하는 것

② 기본 FTS 색인이 놓치는 것 — 조사 · 띄어쓰기 · 조문 번호

③ 조사 떼기 · 2글자 n-gram 보정이 도움이 되는 정도

④ 어디서부터 임베딩 검색(P4)이 필요한지

3주차에 쓰던 DuckDB 에 전문 검색 확장(fts)만 더해 합니다

데이터

개인정보 보호법 현행판 원문

항목	내용
출처	법제처 국가법령정보 DRF API
대상	법률 제21445호(2026.9.11 시행)
규모	조 · 항 · 호 856줄 → 838줄
형식	JSON(gz 압축)
이용허락	저작권법 제7조 — 자유 이용

P4(법령 Q&A 챗봇)와 같은 스냅샷 — 2026-10-28 에 받았다

흐름

법령 JSON 에서 정답률 비교까지

법령 JSON	표로 펴기	LIKE	FTS 색인	보정 색인	15문항
조 · 항 · 호	한 줄 = 항 · 호	글자 그대로	BM25 점수	조사 · 2-gram	hit@1 · hit@3

DuckDB FTS 색인은 테이블 하나에 하나라 보정마다 테이블을 따로 둔다

단계

8단계로 따라 합니다

1

1~2. 준비 · 표로 펴기

INSTALL fts, 삭제 자리는 빼고 개정 표시는 지우기, 번호는 숫자 열로

2

3~4. LIKE · 기본 BM25

순위 없는 LIKE, tokenize 로 색인이 낱말을 나눈 모양 보기

3

5~6. 보정 · 정답률

조사 떼기 · 2-gram 색인, 질문 15개로 hit@1 · hit@3

4

7~8. 저장 · 더 해 보기

Parquet 과 DB 파일에 색인 저장, Kiwi · RRF 로 더 해 보기

일부러 실패해 보기

글자가 같아야만 찾는다

실패	원인	고친 법
제10조가 제2조 앞에	조문 번호를 글자로 정렬	숫자 열 (jo, br) 로
「개인 정보」 0줄	LIKE 는 글자 그대로	2-gram 색인
「유출」 2줄만	「유출되면」은 다른 낱말	조사 떼기 · 2-gram
조문 번호로 못 찾음	기본 설정이 숫자를 지움	WHERE article = …

색인 네 가지 비교

많이 찾는 것과 맞게 찾는 것은 다르다

방법	「유출」	「가명정보」	hit@1 · hit@3
LIKE	27줄	15줄	순위 없음
기본 색인	2줄	2줄	9 · 14
조사 떼기	4줄	15줄	10 · 14
2글자 n-gram	27줄	15줄	10 · 13

2-gram 은 낱말 경계를 몰라 「위탁자」로 8줄을 찾는다 — LIKE 5줄보다 3줄이 엉뚱한 일치

확인 포인트

이 숫자가 같게 나오면 맞습니다

표	856줄에서 삭제 자리 18줄을 빼고 838줄
LIKE	「유출」 27줄, 「개인정보」 424줄 · 「개인 정보」 0줄
정답률	hit@1 기본 9 · 조사 떼기 10 · 2-gram 10(15문항)
남는 한계	「유출되면 알려야」는 세 색인 모두 제34조를 놓침

프로젝트 M6 · 기초 미니 마무리

M6 마무리

BM25 는 같은 글자가 있어야만 점수를 줍니다

- ✓ 조사 목록에 어미를 넣고 hit@1 다시 재기
- ✓ Kiwi 로 명사만 뽑아 색인해 한 줄 더하기
- ✓ 조문 번호는 WHERE 로 먼저 찾는 함수 만들기

다음 프로젝트

P4 법령 Q&A 챗봇