프로젝트 M7 · 기초 미니 · 코랩 · 반나절~하루

영화 리뷰 낱말 세기

긍정 · 부정 리뷰에 유난히 많은 낱말

수도권ICT 이노베이션스퀘어
데이터 엔지니어링 & RAG 파이프라인 160H · 3기

이 프로젝트의 목표

다 끝내면 말할 수 있는 것

① 5만 건 중 분석에 쓴 리뷰 수와, 무엇을 왜 뺐는지

② 불용어를 빼지 않으면 「영화」가 1위가 되는 이유

③ 「긍정 비율」만으로 줄 세우면 틀리는 이유

④ 로그 오즈와 더하기 1 평활이 그것을 고치는 방법

형태소 분석기 없이 정규식 규칙과 3주차 DuckDB 로 셉니다

데이터

정답 감성이 붙은 영화 리뷰 말뭉치

항목	내용
출처	NSMC(Lucy Park) ratings_test.txt
규모	50,000건 · 긍정 25,173 · 부정 24,827
열	id · document · label(1 · 0)
형식	탭으로 나눈 TSV(gz 압축)
이용허락	CC0 1.0(퍼블릭 도메인)

학습용 ratings_train.txt(15만 건)도 같은 형식 — 파일 이름만 바꾸면 그대로 돈다

흐름

리뷰 글에서 치우친 낱말까지

TSV	정제	낱말 자르기	DuckDB	로그 오즈
탭 구분	빈 글 · 중복	정규식 · 조사	긍정 · 부정 건수	+1 평활

낱말 표는 한 줄에 낱말 하나인 긴 표 — DuckDB 가 FILTER 로 긍정 · 부정을 나눠 센다

단계

6단계로 따라 합니다

1. **1~2. 준비 · 정제**
   탭으로 읽기, 빈 글 · 같은 행 · 정답이 엇갈린 글 빼기
2. **3. 낱말 자르기**
   한글 · 영문 2글자 이상, 조사 한 번 떼기, 순위를 보고 불용어 정하기
3. **4. 치우친 낱말**
   긍정 비율의 함정, 50번 이상 · 더하기 1 평활 로그 오즈
4. **5~6. 저장 · 더 해 보기**
   Parquet 저장, 지프의 법칙 그래프, 바이그램 세기

일부러 실패해 보기

다섯 번 막혀 보고 고칩니다

실패	원인	고친 법
CSV 로 읽으면 실패	글 안의 쉼표 · 속은 TSV	sep="\t" 로 읽기
정규식이 멈춤	빈 글(NaN) 3건	빈 글 빼고 공백 지우기
1위가 「영화」	불용어를 빼지 않음	순위를 보고 불용어 목록
한 번 나온 낱말이 1위	비율만으로 줄 세움	50번 이상 · 로그 오즈
log(0) 로 멈춤	한쪽에 0번 나온 낱말	모든 건수에 +1

결과

양 끝에 선 낱말

쪽	낱말(로그 오즈)
긍정 끝	재밌었음 4.292 · 명작이다 · 감동적이고
부정 끝	이딴 -4.436 · 최악 -4.327 · 최악이다
영화 요소 +	ost 1.510 · 연기 0.375
영화 요소 −	평점 · 스토리 · 감독 · cg -1.143

「재밌었음 · 재밌었어요」가 따로 세어진다 — 말끝이 다르면 다른 낱말이 되는 규칙의 한계

확인 포인트

이 숫자가 같게 나오면 맞습니다

정제 후	49,110건(같은 행 793 · 엇갈린 글 94행 제외)
낱말 수	330,499개 · 서로 다른 낱말 104,304개
불용어 전후	1위 영화 10,240번 → 평점 1,595번
로그 오즈	50번 이상 771개 · 긍정 1위 재밌었음 · 부정 1위 이딴

프로젝트 M7 · 기초 미니 마무리

M7 마무리

비율이 아니라 건수와 비율을 함께 보는 지표가 필요합니다

- ✓ 「재밌 · 재미있」을 한 낱말로 합쳐 다시 세기
- ✓ 두 낱말 묶음(바이그램) 세기
- ✓ 낱말 자르기를 DuckDB 안에서 해 보기

다음 프로젝트

P6 리뷰 감성 파이프라인