프로젝트 P1 · 개별 · 코랩 · 2~3일

# 아파트 실거래가 대시보드

## 어느 구가 평당 얼마인가, 어제 기준은?

수도권ICT 이노베이션스퀘어
데이터 엔지니어링 & RAG 파이프라인 160H · 3기

이 프로젝트의 목표

# 다 끝내면 말할 수 있는 것

① 평당가가 가장 높은 구와 가장 낮은 구, 그 차이

② 60m² 이하 · 60~85m² · 85m² 초과 평형별 건수와 평균 금액

③ 두 번째 적재 뒤에도 첫 적재 시점의 테이블을 다시 꺼내는 법

**3주차 Iceberg · 5주차 Spark · 7~8주차 Streamlit 으로 한 바퀴를 돕니다**

데이터

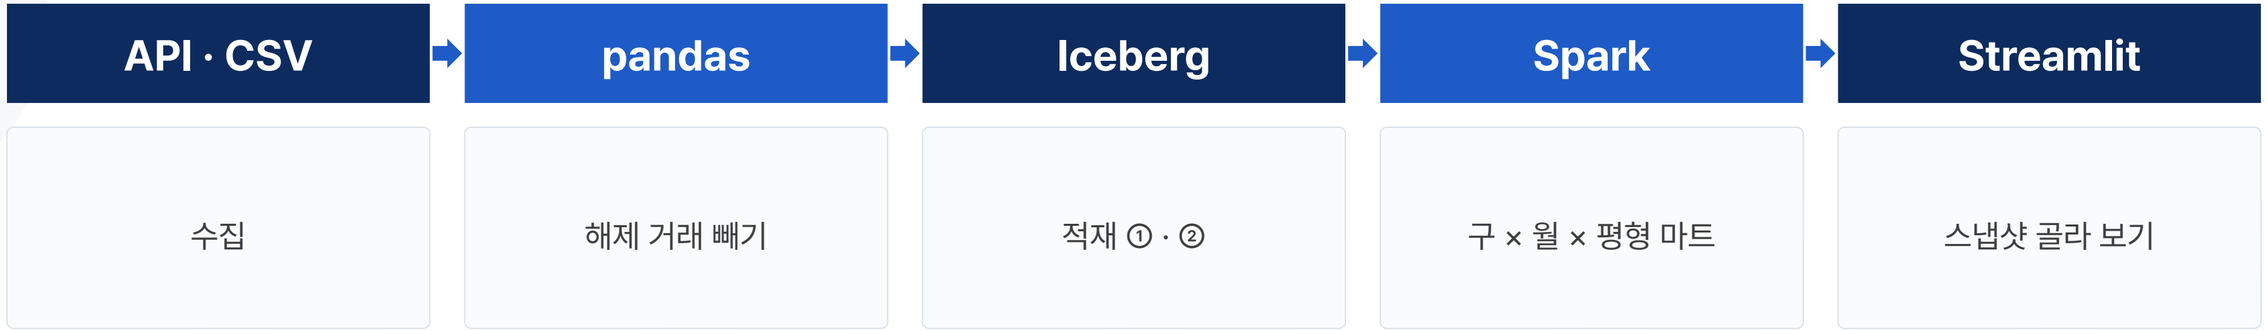
# 국토교통부가 공개하는 실거래 신고

| 항목 | 내용 |
| --- | --- |
| 출처 ① | 공공데이터포털 15126469 OpenAPI(인증키) |
| 출처 ② | 서울 열린데이터광장 OA-21275 스냅샷 |
| 기간 | 계약일 2026년 6~9월(10-28 내려받음) |
| 규모 | 35,610행 · 21개 열 — 아파트 19,102건 |
| 형식 | API 는 XML · 스냅샷은 CSV(CP949) |
| 이용허락 | API 제한 없음 · 스냅샷 공공누리 1유형 |

**키가 없으면 수집을 건너뛰고 스냅샷 CSV 로 진행한다**

흐름

# 두 번 적재하고 어제로 돌아가 보기




**Iceberg 는 적재할 때마다 스냅샷을 남긴다 — 그것이 타임트래블의 근거**

단계

# 9단계로 따라 합니다

1

## 1~3. 준비 · 수집 · 정제

키 없이 불러 403 보기, 아파트만 · 해제 533건 빼기, 평형 · 평당가

2

## 4~5. 1차 적재 · 집계

6~8월 Iceberg 적재, Spark 로 구별 중앙값, 마트 225행

3

## 6~7. 2차 적재 · 타임트래블

9월 덧붙이기 · 마트 덮어쓰기, 스냅샷 번호와 시각으로 어제 읽기

4

## 8~9. 대시보드 · 더 해 보기

Streamlit 앱을 AppTest 로 검사, 스냅샷 라디오로 어제 기준

일부러 실패해 보기

# 네 번 실패하고 이유를 봅니다

| 해 본 것 | 결과 | 배울 점 |
| --- | --- | --- |
| **가짜 키로 API 부르기** | HTTP 403 · XML 오류 | params= 에 디코딩된 키 |
| **금액을 글자로 append** | 스키마가 달라 거절 | 잘못된 파일이 안 섞인다 |
| **없는 열(pric)로 SQL** | 실행 전에 막힘 | 비슷한 이름을 알려 준다 |
| **없는 스냅샷 번호로 읽기** | 오류 | 정리한 만큼 못 돌아간다 |

확인 포인트

# 이 숫자가 같게 나오면 맞습니다

| | |
|---|---|
| **정제 후** | 18,569건(해제 533건 제외) |
| **1차 적재** | 14,928행(6~8월) · 마트 225행 |
| **평당가** | 1위 강남구 12,466만원 · 꼴찌 도봉구 2,520만원 |
| **2차 적재** | 원본 18,569행 · 마트 300행, 어제 스냅샷은 그대로 |

프로젝트 P1 · 개별 마무리

# P1 마무리

스냅샷 하나로 「어제 본 숫자」를 그대로 재현했습니다

- ✔ 키로 25개 구 × 넉 달을 모아 스냅샷과 비교
- ✔ 늦게 들어온 해제 신고를 delete 로 처리
- ✔ 건축년도 구간 필터 붙이기

다음 프로젝트

**P2 날씨 × 따릉이 수요**