프로젝트 P4 · 개별 · 코랩 · 6~8시간

법령 Q&A 챗봇

답보다 먼저 「몇 조 몇 항」을 댄다

수도권ICT 이노베이션스퀘어
데이터 엔지니어링 & RAG 파이프라인 160H · 3기

이 프로젝트의 목표

다 끝내면 말할 수 있는 것

① 현행판과 시행예정판이 API 에서 어떻게 다르게 나오는지

② 조문 단위로 자르면 고정 500자보다 출처가 얼마나 정확한지

③ 검색 결과에 조문 번호를 붙여 LLM 에 넘기는 방법

7주차 RAG 흐름(청킹 · 임베딩 · Qdrant)을 법령에 맞게 다시 짭니다

데이터

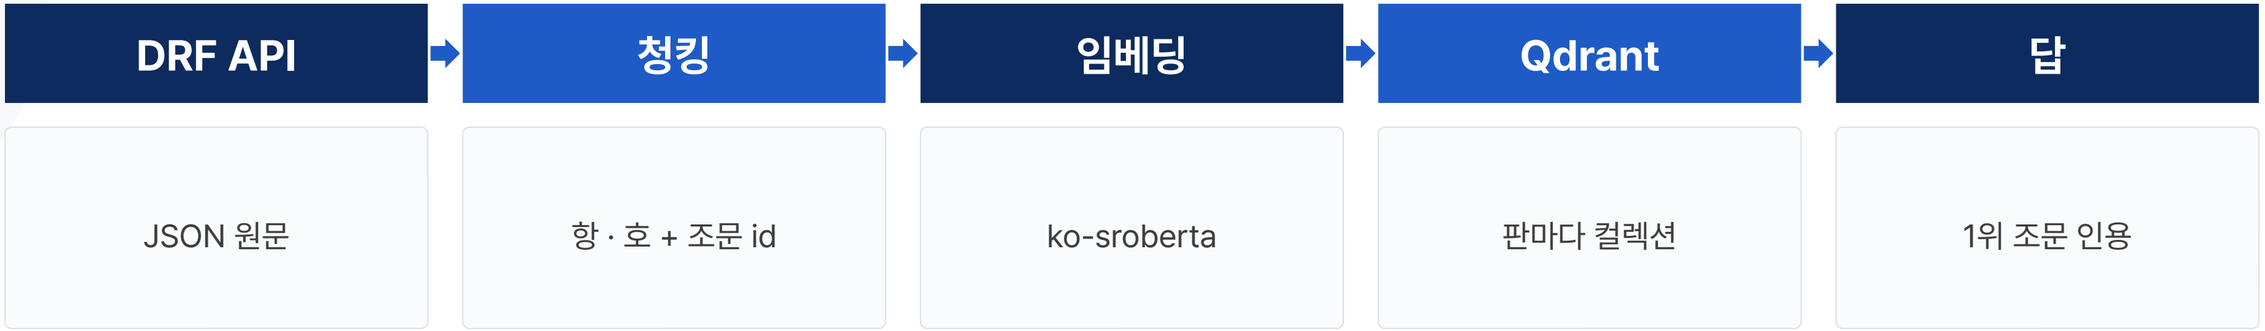
개인정보 보호법 원문 — 두 판

항목	내용
출처	법제처 국가법령정보 공동활용 DRF API
현행판	법률 제21445호 · 2026.9.11 시행
시행예정판	법률 제21910호 · 2027.3.9 시행
규모	조문 127개 · 131개(파일당 약 52KB)
형식	JSON(gzip) · 2026-10-28 받은 스냅샷
이용허락	저작권법 제7조 — 보호받지 않는 저작물

API 를 직접 불러 본 뒤에는 스냅샷으로 — 누가 언제 돌려도 숫자가 같다

흐름

조문 번호가 끝까지 따라가는 RAG



임베딩 jhgan/ko-sroberta-multitask(768차원) · Qdrant 는 메모리 모드

단계

10단계로 따라 합니다

1. **1~3. 준비 · API · 구조**
   nw=2 로 시행예정판 찾기, 항이 list · dict · 없음 세 모양
2. **4~5. 청킹 · 두 판 비교**
   항 하나 · 400자 넘으면 호 하나씩, 새로 생긴 조문 찾기
3. **6~7. 임베딩 · 질문**
   Qdrant 컬렉션 둘에 넣고, 같은 질문을 두 판에 던지기
4. **8~10. 대조 · 답 생성**
   고정 500자와 정답률 비교, (키가 있으면) 조문 인용 답

일부러 실패해 보기

실패가 말해 주는 것

해 본 것	결과	배울 점
OC 를 빼고 부르기	HTTP 200 + 설명 문장	기대한 키부터 확인
항을 as_list 없이 돌리기	TypeError	한 건이면 dict 로 온다
1536차원 컬렉션에 넣기	차원이 맞지 않아 실패	모델과 컬렉션 차원 일치
고정 500자로 자르기	출처 3 / 9 만 맞음	구조대로 자르고 번호 남기기

확인 포인트

이 숫자가 같게 나오면 맞습니다

조각 수	현행판 605개 · 시행예정판 629개
새 조문	제28조의12 ~ 제28조의15 네 조문(AI 개발 이용)
1위 조문	유출 질문 → 제34조제1항 · 아동 → 제22조의2제1항
정답률	조문 청킹 9 / 9 · 고정 500자 3 / 9

프로젝트 P4 · 개별 마무리

P4 마무리

구조대로 자르고 번호를 남기는 것이 출처 달린 RAG 의 핵심입니다

- ✓ **시행령을 함께 넣고 Qdrant 필터로 골라 검색**
- ✓ **지어낸 조문 번호를 찾는 인용 검증 함수**
- ✓ **Streamlit 으로 현행 · 시행예정 선택 화면**

다음 프로젝트

P5 보도자료 요약 · 검색기