프로젝트 P5 · 개별 · 코랩 · 2~3일

보도자료 요약 · 검색기

「이번 달 ○○ 정책 요약해줘」에 근거와 함께

수도권ICT 이노베이션스퀘어
데이터 엔지니어링 & RAG 파이프라인 160H · 3기

이 프로젝트의 목표

다 끝내면 말할 수 있는 것

① 원본 PDF 와 뽑아낸 텍스트를 버킷을 나눠 두는 이유

② 검색 결과에 「이번 달」 조건을 거는 방법(payload 필터)

③ LLM 없이 검색기가 하는 일과, LLM 을 붙이면 달라지는 일

4주차 레이크(MinIO)와 7주차 RAG 를 한 줄로 잇습니다

데이터

보건복지부 한 달치 보도자료

항목	내용
출처	보건복지부 누리집 「보도자료」 게시판
기간	2026-10-01 ~ 10-28 게시분(10-28 수집)
규모	83건 · 37.4MB(게시물마다 첫 PDF)
형식	PDF — zip 두 묶음(1~15일 · 16~28일)
이용허락	게시물마다 공공누리 제1유형 확인

목록 파일 mohw_press_202610.jsonl 에 제목 · 날짜 · 부서 · 원문 주소

흐름

PDF 에서 근거 달린 요약까지



원본은 press-raw, 텍스트는 press-text — 추출 규칙을 바꾸면 원본에서 다시 뽑는다

단계

9단계로 따라 합니다

1. **1~3. 준비 · 수집 · MinIO**
   robots.txt 확인 뒤 PDF 받기, 버킷 press-raw 에 83개 올리기

2. **4~5. 추출 · 청킹**
   쪽 번호 지우고 press-text 로, 500자 · 50자 겹침 조각

3. **6~7. 임베딩 · 검색**
   768차원 벡터를 Qdrant 에, 날짜 Range 로 이번 달만

4. **8~9. 요약 · 정리**
   주제만 떼어 근거 세 건, (키가 있으면) gpt-4o-mini 요약

일부러 실패해 보기

실패가 말해 주는 것

해 본 것	결과	배울 점
버킷 없이 올리기	NoSuchBucket	버킷은 먼저 만든다
HTML 을 PDF 로 읽기	PdfReadError	앞 다섯 글자 %PDF- 확인
겹침이 조각보다 큼	ValueError	chunk_overlap < chunk_size
1536차원 벡터 넣기	차원이 맞지 않아 실패	모델을 바꾸면 다시 적재

확인 포인트

이 숫자가 같게 나오면 맞습니다

원본	press-raw 83개 · 37.4MB
텍스트	83건 361,824자 → 조각 998개(최장 499자)
의료 수가	1위 10/28 지역 · 필수의료 수가(mohw_1492342)
노인 돌봄	1위 10/19 mohw_1492261 · 2위 10/13 mohw_1492213

프로젝트 P5 · 개별 마무리

P5 마무리

출처가 붙은 요약이어야 보도자료 검색기로 쓸 수 있습니다

- ✓ **Streamlit 으로 질문 상자와 답 · 출처 화면**
- ✓ **매일 아침 수집부터 적재까지 Airflow DAG**
- ✓ **다른 부처 보도자료를 넣고 부처 payload 로 거르기**

다음 프로젝트

P6 리뷰 감성 파이프라인