프로젝트 P6 · 개별 · 코랩 · 2~3일

리뷰 감성 파이프라인

리뷰 5만 건, 어느 주제가 가장 부정적인가

수도권ICT 이노베이션스퀘어
데이터 엔지니어링 & RAG 파이프라인 160H · 3기

이 프로젝트의 목표

다 끝내면 말할 수 있는 것

① 5만 건 중 분석에 쓸 수 있는 리뷰 수와 뺀 이유

② 키 없이 만든 기준 모델의 정확도 — LLM 이 넘어야 할 선

③ 연기 · 스토리 · 연출 · 영상 · 음악 중 가장 부정적인 주제

MongoDB(2주차) · Spark(5주차) · Iceberg(18장) · LLM(7주차)을 한 줄로 잇습니다

데이터

정답 감성이 붙은 실제 영화 리뷰

항목	내용
출처	NSMC(네이버 영화 리뷰, Lucy Park)
파일	ratings_test.txt(평가용)
규모	50,000행 · 3개 열(id · document · label)
형식	탭으로 나뉜 TSV · gzip 압축
이용허락	CC0 1.0(퍼블릭 도메인)
선택	gpt-4o-mini — 키가 있을 때 표본 50건

정답(긍정 1 · 부정 0)이 있어 모델이 얼마나 맞히는지 숫자로 잰다

흐름

원본은 문서 DB 에, 결과는 Iceberg 에

NSMC	MongoDB	Spark	모델 · 태깅	Iceberg	DuckDB
리뷰 TSV	원본 적재	빈 글 · 중복 정제	감성 · 주제	스냅샷 2개	주제별 집계

원본을 고치지 않고 보관해 두면 정제 기준이 바뀌어도 다시 시작할 수 있다

단계

9단계로 따라 합니다

1. **1~3. 준비 · MongoDB 적재**
   Java · 라이브러리 설치, mongod 를 27027 에 띄워 리뷰 하나를 문서 하나로

2. **4. Spark 정제**
   두 글자 안 되는 글 333건, 정답이 엇갈린 같은 글 51개 빼기

3. **5~7. 감성 · 주제**
   TF-IDF + 로지스틱 회귀 기준선, 규칙 주제, (키가 있으면) LLM 50건

4. **8~9. 쌓기 · 집계**
   Iceberg 에 두 묶음으로 덧붙이고 DuckDB 로 주제별 긍정 비율

일부러 실패해 보기

단계마다 한 번씩 막혀 봅니다

실패	원인	고친 법
서버보다 먼저 접속	mongod 가 아직 없다	띄운 뒤 ping 으로 기다리기
같은 문서 다시 넣기	_id 가 겹친다	막혀서 원본이 그대로
Spark 열에 len()	열은 나중에 계산할 식	F.length 를 쓴다
원본으로 TF-IDF	빈 글(NaN)이 섞였다	정제한 표로 학습
label 을 글자로 append	Iceberg 스키마와 형이 다르다	형을 맞춰 덧붙이기
자유로운 글로 답한 LLM	JSON 으로 못 읽는다	json_object 형식 지정

막히는 자리를 먼저 보면 바른 방법을 쓰는 이유가 남는다

확인 포인트

이 숫자가 같게 나오면 맞습니다

적재	50,000건 — 부정 24,827 · 긍정 25,173, 빈 글 3건
정제 후	48,532건(짧은 글 333 · 엇갈린 글 51 제외)
기준 모델	평가 9,707건에서 정확도 0.849
스냅샷	2개 — 첫 스냅샷 4,853행 · 지금 9,707행
주제별	가장 부정 story 0.355 · 가장 긍정 music 0.731

프로젝트 P6 · 개별 마무리

P6 마무리

LLM 을 붙이기 전에 넘어야 할 기준선을 직접 세웠습니다

- ✓ 길이 기준을 5글자로 올려 정확도 비교하기
- ✓ ratings_train 15만 건으로 학습해 보기
- ✓ LLM 결과를 reviews.llm_tags 로 따로 쌓아 조인

다음 프로젝트

P7 데이터 품질 리포트 자동화