프로젝트 P7 · 개별 · 코랩 · 2~3일

데이터 품질 리포트 자동화

틀린 데이터가 조용히 흐르지 않게

수도권ICT 이노베이션스퀘어
데이터 엔지니어링 & RAG 파이프라인 160H · 3기

이 프로젝트의 목표

다 끝내면 말할 수 있는 것

① 실거래 자료에 필요한 품질 규칙과 그 기준값을 고른 이유

② 경고가 날 때 데이터가 틀렸는지 규칙이 틀렸는지 가리는 법

③ 열 빠짐 · 단위 바뀜 · 늦게 온 묶음을 각각 잡는 규칙

pandas 와 DuckDB(14~15장)로 검사하고, Airflow(8주차)로 매일 돌립니다

데이터

P1 과 같은 서울 부동산 실거래 자료

항목	내용
출처	서울 열린데이터광장 OA-21275
기간	계약일 2026년 6~9월(10-28 받음)
규모	35,610행 · 21개 열
형식	CSV · CP949 인코딩
이용허락	공공누리 1유형(출처표시)

한 달치를 묶음 하나로, 다음 달 1일에 도착한 것으로 둔다(연습용 일정)

흐름

규칙은 표로, 결과도 표로



규칙을 고칠 때 코드가 아니라 규칙 표의 값만 바꾼다

단계

9단계로 따라 합니다

1. **1~3. 준비 · 묶음 · 규칙 표**
   모든 열을 글자로 읽어 넉 달을 묶음 넷으로, 규칙 21개를 표에
2. **4~5. 실행기 · 경고 읽기**
   규칙 한 줄을 SQL 한 문장으로, 어긴 행을 보고 규칙 표를 고치기
3. **6~7. 결과 쌓기 · 리포트**
   같은 날을 다시 돌려도 한 벌만, 네 달을 차례로 넣기
4. **8~9. 깨진 묶음 · Airflow**
   일부러 깨뜨린 묶음 넷을 잡고, @daily DAG 로 매일 한 번

일부러 실패해 보기

깨뜨린 묶음 넷, 잡은 규칙

도착일	깨뜨린 것	잡은 규칙
10-02	건물면적(m²) 열을 뺐다	R01 필수 열 FAIL
10-03	금액 만원 → 원(×10,000)	R08 범위 7,243행 · R21
10-04	면적 m² → 평(÷3.3058)	R09 101행 · R20 -71%
10-05	6월 묶음을 다시 보냈다	R19 최근 계약일 97일 전

넷 모두 FAIL — 적재되지 않고 다음 날의 기준에도 섞이지 않는다

경고 읽기

데이터가 틀렸나, 규칙이 틀렸나

R11 건축년도 경고

건축년도 0 인 113행 — 1.09% 로 허용 0.5% 초과

- 모두 분양권 62 · 입주권 51
- 아직 안 지은 아파트라 없는 게 맞다

VS

규칙 표의 값만 고친다

where_sql 에 권리구분 IS NULL — 코드는 그대로

- R11 10,235행 중 0행
- R12 도 해제 거래를 빼고 70행(0.70%)

확인 포인트

이 숫자가 같게 나오면 맞습니다

묶음	10,348 · 10,531 · 7,488 · 7,243행
규칙	21개 — 오류 18 · 경고 3
정상 네 달	모두 PASS, 적재 35,610행
깨진 묶음	넷 모두 FAIL, 적재는 35,610행 그대로
DAG 하루치	09-30 SKIP · 10-01 PASS · 10-03 FAIL

프로젝트 P7 · 개별 마무리

P7 마무리

검사하지 않았는데 통과로 보이는 일을 막았습니다

- ✓ 규칙 종류 pattern 하나 더 만들기
- ✓ FAIL 일 때만 메일 · 슬랙으로 알리기
- ✓ P1 의 Iceberg 적재 앞에 관문 두기

다음 프로젝트

P9 이력 관리 테이블(SCD Type 2)