프로젝트 P8 · 개별 · 코랩 · 2~3일

법령 개정 비교기

무엇이, 언제부터, 어떻게 바뀌나

수도권ICT 이노베이션스퀘어
데이터 엔지니어링 & RAG 파이프라인 160H · 3기

이 프로젝트의 목표

다 끝내면 말할 수 있는 것

① 조문을 순서도 글자도 아닌 번호 쌍으로 맞춰야 하는 이유

② 2027.3.9 시행판에서 실제로 바뀌는 조문과 가짜 변경

③ 변경 내역을 검색 가능한 근거로 만들어 질문에 답하는 법

JOIN(2주차) · Parquet · DuckDB(3주차) · 임베딩 · Qdrant(7주차)로 대비표를 만듭니다

데이터

개인정보 보호법 두 판의 원문

항목	내용
출처	법제처 국가법령정보 DRF Open API
현행판	법률 제21445호 · 2026.9.11 시행
시행예정판	법률 제21910호 · 2027.3.9 시행
규모	조문 127개 · 131개
형식	JSON · gzip(2026-10-28 스냅샷)
이용허락	저작권법 제7조 — 보호받지 않는 저작물

P4 와 같은 파일 — API 로 직접 받는 방법은 P4 2단계

흐름

두 판의 원문에서 대비표와 검색까지

두 판 JSON	조문 표	맞추기	항 · 호 diff	변경 표	Qdrant
현행 · 시행예정	열쇠 (jo, br)	신설 · 변경 등	difflib	Parquet · DuckDB	질문 → 두 판

바뀐 줄만 임베딩한다 — 「무엇이 바뀌었나」의 답은 바뀐 줄 안에만 있다

단계

9단계로 따라 합니다

1. **1~3. 준비 · 조문 표 · 맞추기**
   조문 하나를 한 줄로, 번호 쌍으로 완전 외부 조인해 네 갈래로

2. **4~5. 항 · 호 diff**
   한 줄씩 글자 diff, 개정 표시 · 띄어쓰기 · 내용으로 종류 가르기

3. **6. 표로 남기기**
   조문 표 · 항호 표를 Parquet 으로, DuckDB 로 다시 질문

4. **7~9. 검색 · 답**
   바뀐 32줄을 ko-sroberta 로 Qdrant 에, 두 판 나란히 · (키가 있으면) 요약

일부러 실패해 보기

잘못 맞추면 가짜 변경이 생긴다

잘못 맞춘 법	결과	원인
번호를 글자로 정렬	제28조의12 가 29번째	왼쪽부터 한 글자씩 비교
순서로 맞추기	71개가 「바뀜」	신설 4개 뒤로 한 칸씩 밀림
JSON 통째로 비교	127개 전부 「바뀜」	조문시행일자 칸이 다르다
번호 쌍으로 맞추기	신설 4 · 변경 3	바른 방법

바른 열쇠는 숫자 두 칸 (조문번호, 가지번호) — 제28조의12 는 (28, 12)

가짜 변경 가르기

변경 3줄은 모두 표시만 바뀌었다

tag_only 2줄

제2조 머리 · 제7조의9제1항 — 개정 표시에 「, 2026.9.8」

- 개정 표시는 언제 바뀌었다는 기록
- 조문의 내용은 그대로

VS

spacing 1줄

제37조의2제1항 — 「인공지능 기술」 → 「인공지능기술」

- 법이 직접 붙인 용어 정비
- 버리지 않고 종류로 남긴다

확인 포인트

이 숫자가 같게 나오면 맞습니다

조문 맞추기	신설 4 · 변경 3 · 삭제 0 · 그대로 124
항 · 호 줄	신설 31줄 · 변경 3줄 — 내용 변경은 0줄
Qdrant	신설 31 + 띄어쓰기 1 = 32줄
AI 질문 1위	제2조제9호 「인공지능기술」 정의 신설(0.517)
CCTV 질문	1위 점수 0.301 — 관련 조문 없음으로 답할 질문

프로젝트 P8 · 개별 마무리

P8 마무리

이번 개정의 실질이 신설 31줄이라는 것을 직접 가려냈습니다

- ✓ IsHistory 로 판 하나 더 받아 세 판 비교하기
- ✓ 시행령 두 판으로 같은 노트북 돌리기
- ✓ Streamlit 으로 색칠한 대비표 화면 만들기

다음 프로젝트

P9 이력 관리 테이블(SCD Type 2)