프로젝트 P9 · 개별 · 코랩 · 2~3일

이력 관리 테이블

SCD Type 2 — 그날 있던 대여소 다시 꺼내기

수도권ICT 이노베이션스퀘어
데이터 엔지니어링 & RAG 파이프라인 160H · 3기

이 프로젝트의 목표

다 끝내면 말할 수 있는 것

① 네 판 사이에 생기고 · 닫히고 · 바뀐 대여소 수와 내용

② 「2026-06-10 기준 목록」을 꺼내는 SQL과 경계 날짜의 함정

③ 타임트래블(적재 시간)과 SCD2(유효 시간)가 답하는 질문

④ 같은 변경을 두 번 넣어도 이력이 겹치지 않게 하는 법

pyiceberg(3주차 18 · 21장)로 서버 없이 Iceberg 에 이력을 쌓습니다

데이터

반년마다 통째로 다시 올라오는 대여소 목록

항목	내용
출처	서울 열린데이터광장 OA-13252
판	24.12 · 25.6 · 25.12 · 26.6월 기준
규모	2,766 → 2,780 → 2,799 → 2,789곳
형식	엑셀(xlsx) · 판마다 290KB 안팎
이용허락	공공누리 1유형(출처표시)

파일에는 「몇 월 기준」만 있어 기준 달의 마지막 날을 그 판의 기준일로 둔다

흐름

네 판을 비교해 닫고, 열고

네 판	변경 감지	SCD2 병합	Iceberg	시점 조회
24.12 ~ 26.6	row_hash 비교	upsert	bike.station_dim	그날 기준 목록

바뀌면 옛 줄을 닫고(valid_to) 새 줄을 연다(valid_from) — 키는 (station_id, valid_from)

단계

8단계로 따라 합니다

1. **1~3. 준비 · 읽기 · 변경 감지**
   네 판을 같은 모양으로, 값 여섯 가지를 해시로 비교
2. **4~5. 첫 적재 · SCD2 병합**
   24.12 판으로 테이블을 만들고, 새 판마다 닫고 열기
3. **6~7. 시점 조회 · 타임트래블**
   반열린 구간으로 그날 목록, 적재 직후 테이블과 비교
4. **8. 멱등 처리**
   같은 변경을 두 번 넣어 보고, 적재 기록으로 옛 판 막기

일부러 실패해 보기

조용히 틀리는 자리 넷

해 본 것	결과	고친 법
열마다 != 로 비교	LCD 1,700곳 넘게 「바뀜」	row_hash 로 비교
BETWEEN 으로 조회	6월 30일 2,811곳	반열린 구간 2,789곳
변경 사건을 두 번 덧붙임	2,860줄 — 이력 겹침	현재 상태와 비교해 upsert
거치대 수를 글자로 넣기	Iceberg 가 거절	형을 맞춰 넣기

끝 날짜는 포함하지 않는다 — valid_from <= 날짜 < valid_to

타임트래블과 SCD2

두 방식은 서로 다른 시간에 답한다

	Iceberg 타임트래블	SCD Type 2
시간의 뜻	적재 시간 — 언제 쓰였나	유효 시간 — 언제 그 값이었나
시간 축	엔진이 커밋할 때 저절로	우리가 valid_from 을 정함
얼마나 남나	스냅샷을 정리하면 사라짐	지우지 않는 한 영구
늦게 온 자료	받은 날의 스냅샷으로	과거 날짜로 끼워 넣기

SCD2 테이블을 Iceberg 에 두면 두 시간을 함께(이중 시간) 물을 수 있다

확인 포인트

이 숫자가 같게 나오면 맞습니다

변경 감지	신설 27 · 43 · 9, 폐쇄 13 · 24 · 19, 변경은 마지막 판 3곳
병합 후	전체 2,848줄 · 현재 2,789줄
시점 조회	2026-06-10 기준 2,808곳 · 2025-06-10 기준 2,787곳
타임트래블	세 번째 적재 직후 2,836줄 · 현재 2,799줄
다시 병합	같은 판을 한 번 더 넣어도 2,848줄

프로젝트 P9 · 개별 마무리

P9 마무리

덮어쓰면 사라질 「그때의 모습」을 줄로 남겼습니다

- ✓ 옛 판을 더 받아 이름이 가장 많이 바뀐 대여소 찾기
- ✓ M1 대여 기록에 그날 기준 대여소 이름 붙이기
- ✓ 스냅샷 정리 뒤에도 SCD2 이력이 남는지 보기

다음 프로젝트

T1 서울 실시간 도시 상황판