프로젝트 T1 · 팀 · 내 컴퓨터 Docker · 3일

서울 실시간 도시 상황판

「지금 광화문 왜 붐벼?」에 근거 붙이기

수도권ICT 이노베이션스퀘어
데이터 엔지니어링 & RAG 파이프라인 160H · 3기

이 프로젝트의 목표

다 끝내면 말할 수 있는 것

① API 응답이 Kafka 를 거쳐 레이크 어느 경로에 쌓이는지

② 같은 시각 자료를 두 번 받아도 Spark 에서 한 번만 세는 법

③ 「왜 붐벼?」에 숫자(혼잡도 표)와 글(행사 · 통제)을 함께 붙이는 법

4~8주차의 Kafka · MinIO · Spark · Qdrant · Airflow 를 한 줄로 잇습니다

데이터

서울시가 5분마다 갱신하는 실시간 API

항목	실시간 도시데이터	따릉이 실시간
출처	OA-21285 (citydata)	OA-15493 (bikeList)
내용	장소 100여 곳의 혼잡도 · 글	대여소별 거치 대수
갱신	5분마다	실시간
sample 키	광화문·덕수궁 한 곳	5행까지
형식	JSON (OpenAPI)	JSON (OpenAPI)
이용허락	공공누리 1유형	공공누리 1유형

응답 속 연합뉴스 기사(LIVE_YNA_NEWS)는 공공누리 대상이 아니라 담지 않는다

흐름

API 응답에서 「왜 붐벼?」까지



숫자는 Spark 로 집계하고, 글은 RAG 근거로 — Airflow DAG 가 매시간 부른다

단계

10단계로 따라 합니다

1

1~2. 준비 · 인프라

인증키(없으면 sample), compose 로 Kafka · MinIO · Qdrant 띄우기

2

3~5. 수집 · 적재

API 한 건 뜯어보기, Producer 로 토픽에, Consumer 가 raw 층에

3

6~8. 집계 · RAG

Spark 중복 제거 · 혼잡도 마트, 글을 Qdrant 에, 숫자와 글로 답

4

9~10. DAG · 정리

함수 네 개를 매시간 DAG 로, Airflow 컨테이너에서 검사, down -v

일부러 실패해 보기

단계마다 한 번씩 깨 봅니다

해 보는 것	나오는 오류	바른 방법
포트 9999 로 붙기	KafkaException	localhost:9092
서비스 이름 citydat	HTTP 200 인데 ERROR-500	RESULT.CODE 확인
dict 를 그대로 보내기	bytes-like 필요	json.dumps 로 글자로
없는 버킷에 쓰기	NoSuchBucket	lake 버킷 먼저 만들기
없는 열 고르기	UNRESOLVED_COLUMN	실행 전에 열 이름 검사
384차원 벡터 넣기	expected dim: 768	모델 차원에 맞추기
노트북에서 DAG 읽기	No module 'airflow'	Airflow 컨테이너에서

확인 포인트

실시간이라 숫자 대신 「형태」로 봅니다

수집	혼잡도가 여유 · 보통 · 약간 붐빔 · 붐빔 넷 중 하나
적재	보낸 수와 같은 파일 수, 경로는 raw/city/dt=.../hour=...
마트	중복 제거 뒤 원본보다 적거나 같고, 장소마다 한 행 · level 1~4
답	장소가 광화문·덕수궁으로 잡히고 근거가 모두 같은 장소
DAG	읽기 오류 No data found, 태스크 넷

팀 역할

네 갈래로 나눠 키웁니다

01

수집 · 스트리밍

3~5단계

API · Producer · Consumer

02

레이크 · Spark

2 · 6단계

인프라 · 혼잡도 마트

03

RAG · 서비스

7~8단계

Qdrant 문서 · 답하기

04

오케스트레이션

9~10단계

Airflow DAG · 정리

처음에는 한 사람이 노트북 하나로 끝까지 돌려 보고, 그다음 역할별로 나눠 키웁니다

프로젝트 T1 · 팀 마무리

T1 마무리

한 출처의 숫자와 글을 한 파이프라인에서 함께 다뤘습니다

- ✓ 내 키로 장소 10곳 이상, 1분마다 하루 쌓기
- ✓ 시간대별 혼잡도와 따릉이 거치율 관계 그리기
- ✓ Streamlit 으로 「장소 고르기 + 질문」 상황판

다음 프로젝트

T3 쇼핑몰 CDC → AI 상담봇