프로젝트 T2 · 팀 · 코랩 · 따라하기 4~5시간

정책 · 민원 인텔리전스

늘어난 민원 분야 × 국회 발언 잇기

수도권ICT 이노베이션스퀘어
데이터 엔지니어링 & RAG 파이프라인 160H · 3기

이 프로젝트의 목표

다 끝내면 말할 수 있는 것

① 2024 → 2025년 고충민원이 가장 많이 늘어난 분야와 증가율

② 그 분야 소관 상임위원회의 관련 발언(날짜 · 발언자 · 직위)

③ Airflow 태스크로 나눌 때 어디서 끊고 무엇을 파일로 남기는지

5~8주차의 Spark · 스트리밍 · Qdrant · Airflow 로 숫자와 글을 엮습니다

데이터

키 없이 받는 실제 공개 자료 두 가지

항목	고충민원 통계	국회 회의록
출처	공공데이터포털 · 국민권익위	열린국회정보 API · 원문
기간	2015~2025년	2025년 9~12월 회의 8건
규모	286행 · 26개 분야	발언 2,788건
형식	CSV · cp949	JSONL(gz) 스냅샷
이용허락	제한 없음	저작권법 제24조

둘 다 2026-10-28 에 받아 둔 스냅샷 — 2 · 3단계에서 직접 받는 코드도 돌린다

흐름

원본에서 위원회 발언 검색까지

raw	landing	bronze	silver · gold	Qdrant	검색
민원 CSV 그대로	회의마다 파일 하나	Structured Streaming	정제 · 분야↔위원회	발언 조각 색인	소관 위원회 필터

같은 함수를 Airflow DAG 의 태스크 다섯 개로 묶는다

단계

11단계로 따라 합니다

1

1~3. 준비 · 수집

민원 CSV 를 raw 에 그대로, 회의록 API · 원문을 발언 단위로

2

4~6. 스트리밍 · 레이크

landing → bronze, lag() 로 분야별 증감, 발언 정제 · 연결표

3

7~9. RAG · 서비스

청킹 · 임베딩 · Qdrant, 위원회 필터 검색, 요약 · Streamlit

4

10~11. DAG · 발표

태스크 다섯 개로 나눠 DAG 로, 더 해 보기 · 한계 밝히기

일부러 실패해 보기

단계마다 한 번씩 깨 봅니다

해 보는 것	나오는 것	바른 방법
CSV 를 UTF-8 로 읽기	UnicodeDecodeError	cp949 로 읽기
Spark 에서 인코딩 빼기	오류 없이 깨진 글자	인코딩을 지정
API 필수 값 빼기	HTTP 200 · ERROR-300	RESULT.CODE 확인
스키마 없이 readStream	Schema must be specified	스키마를 먼저 준다
필터 없이 넓은 질문	국방위 발언 0개	소관 위원회 필터
bronze 전에 build_gold	PATH_NOT_FOUND	DAG 의 >> 로 순서

확인 포인트

이 숫자가 같게 나오면 맞습니다

스트리밍	1차 2,034건, 다시 돌려도 2,034건, 12월 도착 뒤 2,788건
증가 1위	재정 936 → 3,796건(+305.6%), 2위 교통 +185.4%
정제	40자 이상 발언 1,321건 — 정무위 647 · 기재위 67
색인	발언 조각 1,696개가 모두 Qdrant 에
필터 대조	넓은 질문에 필터가 없으면 국방위 0개, 걸면 1위

팀 역할

네 갈래로 나눠 키웁니다

01

수집 · 스트리밍

2~4단계

민원 · 회의록 · landing

02

레이크 · Spark

5~6단계

증감 · 분야 연결표

03

RAG · 서비스

7~9단계

Qdrant · Streamlit

04

오케스트레이션

10단계

태스크 다섯 · DAG

먼저 모두가 노트북을 한 번 따라한 뒤 자기 역할의 단계를 늘려 갑니다

프로젝트 T2 · 팀 마무리

T2 마무리

숫자가 가리킨 분야로 글 검색을 좁혀 두 데이터를 엮었습니다

- ✓ 인증키로 한 해 국토위 회의를 받아 Kafka 토픽으로
- ✓ 질문 20개로 필터 유무 정답률 재기
- ✓ bronze · silver · gold 를 MinIO + Iceberg 로

다음 프로젝트

T3 쇼핑몰 CDC → AI 상담봇