프로젝트 T4 · 팀 · 코랩 · 2~3주(따라하기 3~4시간)

프로젝트 도우미 튜터 챗봇

노트북 13개를 근거로 답하는 튜터

수도권ICT 이노베이션스퀘어

데이터 엔지니어링 & RAG 파이프라인 160H · 3기

이 프로젝트의 목표

다 끝내면 말할 수 있는 것

① 노트북을 문서로 바꿀 때 남길 것 — 실행 출력은 오류만

② 다시 실행만 된 노트북을 다시 색인하지 않으려면 잴 해시

③ 메타 필터가 없으면 엉뚱한 프로젝트가 1위로 오는 이유

④ 셀 종류 가중이 검색 정확도를 얼마나 바꾸는지

7주차 임베딩 · Qdrant 에 8주차 Streamlit 과 Airflow 를 잇습니다

데이터

이 과정이 공개한 따라하기 노트북

항목	내용
출처	과정 공개 자료실 data-eng/projects
대상	따라하기 노트북 13개
범위	M1~M4 · P1~P6 · T1~T3
기간	2026-10-29 받은 스냅샷
규모	셀 1,101개 → 문서 1,027개
형식	ipynb(JSON) · jsonl.gz 한 파일
이용허락	과정이 직접 만들어 공개 — 문제 없음

노트북 출력에 보이는 공공데이터의 출처 · 이용허락은 각 노트북 1단계에 있다

흐름

노트북 13개에서 근거 붙은 답까지

수집	셀 문서	Parquet	Qdrant	검색	ask()
목록 API 노트북 JSON	설명 · 코드 오류 출력	프로젝트 파티션 내용 해시	ko-sroberta 임베딩	메타 필터 셀 종류 가중	Streamlit 근거 붙은 답

매일 collect → reindex → smoke 를 Airflow DAG 가 돈다

단계

11단계로 따라 합니다

1

1~3. 준비 · 수집

스냅샷 받기, 목록 API 로 노트북 받기, 셀을 문서로(출력은 오류만)

2

4~5. 레이크

128토큰 한도에 맞춰 조각내기, 문서 표 Parquet 과 내용 해시 증분

3

6~9. RAG · 서비스

Qdrant 메타 필터 · 셀 종류 가중, 질문 10개 정확도, ask() · Streamlit

4

10~11. 오케스트레이션 · 발표

collect → reindex → smoke DAG, 더 해 보기 · 발표 준비

일부러 실패해 보기

오류보다 무서운 조용한 실패

일부러 해 본 것	결과	그래서
없는 프로젝트 받기	HTTPError 404	목록(API)에서 출발
긴 셀을 통째로 임베딩	앞 128토큰만 쓰인다	300자 조각으로
파일 해시로 바뀜 재기	실행만 해도 바뀜	문서 해시로 잰다
stage 를 글자 "6" 으로	오류 없이 빈 결과	정수로 넘긴다
코드 셀만 남은 레이크	smoke 0.6 < 0.8 실패	DAG 가 멈춰 알린다

실패를 먼저 보면 왜 그렇게 고쳤는지가 남는다

확인 포인트

이 숫자가 같게 나오면 맞습니다

문서	1,027개(설명 555 · 코드 426 · 오류 46) → 조각 1,544개
증분	바로 다시 돌리면 [] · 고친 판은 ['M3'] 하나만
정확도	질문 10개 중 9개(0.9)
빼 보기	낱말 보너스 없이 0.6 · 가중 없이 0.8 · 코드 셀만 0.6

팀에서 나누는 법

역할 네 갈래 — 단계를 나눠 맡습니다

01

수집

2~3단계

새 프로젝트 자동 반영

02

레이크

4~5단계

Iceberg 로 색인 이력

03

RAG · 서비스

6~9단계

질문 30개 · 평가 단추

04

오케스트레이션

10단계

로컬 Airflow · 알림

먼저 모두가 노트북을 한 번 따라한 뒤 자기 역할의 단계를 키웁니다

프로젝트 T4 · 팀 마무리

T4 마무리

답마다 프로젝트 · 단계 · 셀을 근거로 붙이는 튜터를 만들었습니다

- ✓ live 로 돌려 새 프로젝트가 저절로 드는지 보기
- ✓ 문서 표를 Iceberg 로 옮겨 지난주 색인과 비교
- ✓ 발표: 질문 10개의 한계와 판단 함께 밝히기

다음 프로젝트

T5 서울 생활 데이터 레이크하우스