프로젝트 T5 · 팀 · 내 컴퓨터 Docker · 3일

서울 생활 데이터 레이크하우스

기관도 키도 다른 자료 넷을 한자리에

수도권ICT 이노베이션스퀘어
데이터 엔지니어링 & RAG 파이프라인 160H · 3기

이 프로젝트의 목표

다 끝내면 말할 수 있는 것

① 생활인구와 상가의 행정동 코드가 어긋나는 곳과 대응표의 근거

② 행정동이 없는 대여소를 좌표로 동에 붙이는 법과 그 오차

③ Spark 쪽에서 쓴 Iceberg 표를 Trino 가 읽는 이유 — REST 카탈로그

4주차 레이크하우스 위에 5주차 Spark 와 8주차 Airflow 를 얹습니다

데이터

2026년 6월 서울 자료 다섯 파일

자료	출처	기준	규모
아파트 실거래	열린데이터 OA-21275	2026년 6~9월 계약	35,610건(6월 5,374)
음식점 상가	공공데이터포털 15083033	2026-06-30 기준	141,126곳
생활인구	열린데이터 OA-14991	2026년 6월	305,280행
따릉이 대여	열린데이터 OA-15182	2026년 6월	81,909행(날짜×대여소)
대여소 정보	열린데이터 OA-13252	26.6월 기준 xlsx	2,789곳

열린데이터광장 넷은 공공누리 1유형(출처표시), 상가정보는 이용허락 제한 없음

왜 어려운가

만든 곳이 다르니 지역 키도 다르다

자료	지역 키	부딪히는 것
아파트 실거래	자치구 + 법정동코드	구 단위에서만 잇는다
음식점 상가	행정동 8자리(2026-06)	생활인구와 21곳 어긋남
생활인구	행정동 8자리(2016 기준)	분동 · 통합이 반영 안 됨
따릉이 대여	대여소 번호 00102	정보엔 102 · 동 없이 좌표만

어긋남을 하나씩 맞춰 하나의 레이크하우스로 만든다

흐름

원본 다섯 개에서 교차 질의까지



매월 Airflow DAG 가 올리기 → 정제 · 적재 → 대조 검사를 차례로 부른다

단계

11단계로 따라 합니다

1

1~3. 준비 · 인프라 · 원본 층

MinIO · Iceberg REST · Trino 띄우기, 다섯 파일을 그대로 raw 버킷에

2

4~5. 읽기 · 키 맞추기 ①

Spark 로 CP949 읽기, 대여소 번호 앞자리 0 · 자치구 이름

3

6~8. 대응표 · 좌표 · 적재

행정동 대응표 11줄, 좌표로 가까운 동 붙이기, Iceberg 표 6개

4

9~11. 질의 · DAG · 정리

Trino 교차 질의, 매월 도는 Airflow DAG, 컨테이너 정리

일부러 실패해 보기

실패를 먼저 보고 고칩니다

일부러 해 본 것	결과	그래서
없는 버킷에 올리기	NoSuchBucket	만든 버킷(raw)에만
실거래를 기본 UTF-8 로	오류 없이 열 이름 깨짐	encoding cp949
앞 7자리가 같으면 짝	두 짝 · 짝 없는 동	근거 있는 대응표
append 를 한 번 더	10,748행(두 배)	overwrite 로 적재
Trino 에 파일 경로로	SYNTAX_ERROR	카탈로그 표 이름으로
대응표 없이 적재	대조 태스크 실패	DAG 가 멈춰 알린다

대응표 없이 적재하면 대조 태스크가 실패해야 정상 — 확인 뒤 되돌린다

확인 포인트

이 숫자가 같게 나오면 맞습니다

대응표	11줄 — 생활인구 424곳이 하나도 빠지지 않는다
대여소	2,789곳 중 2,628곳(94%)만 자치구가 같다
적재	표 6개 · 생활인구 305,280 · 상가 141,126행
카페 1위	생활인구 1만 명당 마포구 연남동 123.0곳
구 단위	25개 구 모두 · 1만 명당 거래 1위 노원구 15.2건

팀에서 나누는 법

역할 네 갈래 — 단계를 나눠 맡습니다

01

수집 · 스트리밍

3~5단계

원본 층 · 번호 맞추기

02

레이크 · Spark

2 · 6~8단계

대응표 · 좌표 · 적재

03

조회 · 서비스

9단계

Trino 교차 질의

04

오케스트레이션

10~11단계

Airflow DAG · 정리

RAG 가 없어 세 번째 역할은 조회 · 서비스(Trino 질의와 그래프)가 맡습니다

프로젝트 T5 · 팀 마무리

T5 마무리

기관마다 다른 키를 맞춰 동네 단위 교차 질의를 만들었습니다

- ✓ 생활인구 7월분을 받아 달만 바꿔 돌리기
- ✓ 행정동 경계(shp)로 중심점 방식과 비교
- ✓ 질의를 Trino 뷰로 저장해 Streamlit 화면에

다음 프로젝트

T6 공공데이터 품질 관제판