프로젝트 T6 · 팀 · 코랩 · 2~3주(따라하기 3~4시간)

공공데이터 품질 관제판

갱신이 멈춘 데이터를 먼저 알아채기

수도권ICT 이노베이션스퀘어
데이터 엔지니어링 & RAG 파이프라인 160H · 3기

이 프로젝트의 목표

다 끝내면 말할 수 있는 것

① 화면 메타만으로 갱신이 멈춘 데이터를 잡는 법과 그 헛알림

② 열 이름이 같아도 바뀐 형식(인코딩 · 따옴표)을 지문으로 잡기

③ 빈 값이 많은 열 중 원래 비어야 정상인 열 구별하기

④ 알림이 뜬 데이터의 이유를 변경 공지에서 찾아 붙이기

7주차 Qdrant 와 8주차 Streamlit · Airflow 로 관제판을 만듭니다

데이터

화면 메타 13개와 받아 둔 스냅샷

자료	출처	시점
화면 메타데이터	데이터셋 13개(서울 10 · 포털 3)	2026-10-29 20:49 수집
대기오염도	열린데이터 OA-2218	2023 · 2024 · 2025년
대여소 정보	열린데이터 OA-13252	24.12 · 25.6 · 25.12 · 26.6
실거래가	열린데이터 OA-21275	계약일 2026년 6~9월
생활인구	열린데이터 OA-14991	2026년 6월
고충민원	공공데이터포털 15131929	T2 와 같은 파일

열린데이터광장 파일은 공공누리 1유형(출처표시), 고충민원은 이용허락 제한 없음

흐름

화면 13개에서 알림과 그 이유까지



Airflow DAG 가 매일 수집 → 규칙 → 색인을 차례로 부른다

단계

11단계로 따라 합니다

1

1~3. 준비 · 수집

화면 하나 뜯어보기, 13개를 1.5초 간격으로 수집, 스냅샷으로 숫자 고정

2

4~7. 메타 표 · 규칙 세 겹

날짜 모양 맞추기, 신선도 · 형식 지문 · 빈 값과 행 수 변화

3

8~9. 알림 · 관제판 · 검색

알림 목록과 Streamlit 관제판, 「이 데이터 왜 끊겼나」 공지 검색

4

10~11. DAG · 발표

매일 수집 → 규칙 → 색인 DAG, 더 해 보기 · 발표 준비

일부러 실패해 보기

성공처럼 보이는 실패를 잡습니다

일부러 해 본 것	결과	그래서
없는 데이터셋 번호로 받기	HTTP 200 · 첫 화면이 온다	상태 코드만 믿지 않는다
대기오염도를 CP949 로 고정	2024년 파일에서 깨진다	파일마다 지문을 잰다
번호를 OA-1499 로 거르기	오류 없이 빈 결과	번호부터 확인한다
수집 전에 규칙 부르기	FileNotFoundError	DAG 의 >> 로 순서를

빈 결과를 「공지 없음」으로, 200 을 「잘 받았다」로 바로 믿지 않는다

확인 포인트

이 숫자가 같게 나오면 맞습니다

신선도	생활인구 — 갱신 주기 매일인데 경과 85일(stale)
형식	대기오염도 형식 변화 3건 — 인코딩이 해마다 바뀐다
행 수	실거래가 8월 7,488건(-28.9%)
알림	7건 — error 4 · warn 2 · info 1
이유	1위: 생활인구 250m 격자 전환으로 생산 종료 안내

팀에서 나누는 법

역할 네 갈래 — 단계를 나눠 맡습니다

01

수집 · 스트리밍

2~3단계

화면 뜯기 · 스냅샷

02

레이크 · 품질

4~7단계

메타 표 · 규칙 세 겹

03

RAG · 서비스

8~9단계

관제판 · 공지 검색

04

오케스트레이션

10~11단계

매일 DAG · 알림

2 · 3단계는 실제 사이트에 요청합니다 — 반복 실행할 때는 LIVE = False 로

프로젝트 T6 · 팀 마무리

T6 마무리

원천이 조용히 바뀌는 것을 규칙 세 겹으로 먼저 알아챘습니다

- ✓ 감시 목록을 모든 프로젝트 데이터셋으로 늘리기
- ✓ 행 수 규칙을 「최근 2개월 신고 미완성」으로
- ✓ 원인 후보를 관제판 알림 표 옆 칸에

함께 볼 프로젝트

P3 · T5 — 생활인구 코드 어긋남